

1. Considera la distribución Exponencial, con función de densidad

$$p(x|\theta) = \theta e^{-\theta x} \quad (0 < x; 0 < \theta).$$

(a) Demuestra que la familia $\text{Gamma}(\theta|\alpha, \beta)$ es conjugada para θ , exhibiendo la regla de actualización de los hiperparámetros de la distribución de θ dada una muestra aleatoria $\mathbf{X} = \{X_1, X_2, \dots, X_n\}$ de $p(x|\theta)$.

(b) Demuestra que $S = \sum_{i=1}^n X_i$ es una estadística suficiente para θ utilizando la definición bayesiana de suficiencia.

$$a) \quad p(\theta|\hat{x}) \propto p(\theta) p(\hat{x}|\theta)$$

$$= \left\{ \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta} \right\} \theta^n e^{-\theta \sum_{i=1}^n x_i}$$

$$\propto \theta^{\alpha+n-1} e^{-\theta (\beta + \sum_{i=1}^n x_i)}$$

$$\Rightarrow p(\theta|\hat{x}) = \text{Gamma}(\alpha+n, \beta + \sum_{i=1}^n x_i)$$

b) Como

$$p(\theta|t_n) \propto p(\theta) p(t_n|\theta) \\ \propto \theta^{\alpha-1} e^{-\beta\theta} p(t_n|\theta)$$

$$\Rightarrow \text{Basta ver que } p(t_n|\theta) \propto \theta^n e^{-\theta t_n}$$

$$\text{Pero } p(x_i|\theta) \sim \text{Gamma}(\alpha=1, \beta=\theta).$$

por lo tanto, por

Theorem 4.6.7 (Generalization of Theorem 4.2.12) Let X_1, \dots, X_n be mutually independent random variables with mgf $M_{X_1}(t), \dots, M_{X_n}(t)$. Let $Z = X_1 + \dots + X_n$. Then the mgf of Z is

$$M_Z(t) = M_{X_1}(t) \cdots M_{X_n}(t).$$

In particular, if X_1, \dots, X_n all have the same distribution with mgf $M_X(t)$, then

$$M_Z(t) = (M_X(t))^n.$$

Example 4.6.8 (Mgf of a sum of gamma variables) Suppose X_1, \dots, X_n are mutually independent random variables, and the distribution of X_i is gamma(α_i, β). From Example 2.3.8, the mgf of a gamma(α, β) distribution is $M_X(t) = (1 - \beta t)^{-\alpha}$. Thus, if $Z = X_1 + \dots + X_n$, the mgf of Z is

$$M_Z(t) = M_{X_1}(t) \cdots M_{X_n}(t) = (1 - \beta t)^{-\alpha_1} \cdots (1 - \beta t)^{-\alpha_n} = (1 - \beta t)^{-(\alpha_1 + \dots + \alpha_n)}.$$

This is the mgf of a gamma($\alpha_1 + \dots + \alpha_n, \beta$) distribution. Thus, the sum of independent gamma random variables that have a common scale parameter β also has a gamma distribution.

A generalization of Theorem 4.6.7 is obtained if we consider a sum of linear functions of independent random variables.

obtenemos lo deseado.

2. Considera el modelo Poisson, con función de probabilidad de la forma

$$\text{Po}(x|\lambda) = \frac{\lambda^x e^{-\lambda}}{x!} \quad (x = 0, 1, \dots; 0 < \lambda).$$

- (a) Muestra que este modelo pertenece a una familia exponencial natural, escribiéndolo en su representación canónica.
- (b) Encuentra $\mathcal{C}_\theta(\mathcal{F})$, la familia conjugada estándar para el parámetro canónico θ . También encuentra $\mathcal{C}_\lambda^\theta(\mathcal{F})$, la familia conjugada inducida por θ sobre λ .
- (c) Demuestra que la familia de distribuciones $\text{Gamma}(\lambda|\alpha, \beta)$ es la familia conjugada estándar para λ , exhibiendo explícitamente la regla de actualización de los hiperparámetros α y β dada una muestra aleatoria $\mathbf{X} = (X_1, \dots, X_n)$ de $\text{Po}(x|\lambda)$. Denota a esta familia por $\mathcal{C}_\lambda(\mathcal{F})$, como lo hicimos en clase.
- (d) Demuestra que $\mathcal{C}_\lambda(\mathcal{F}) = \mathcal{C}_\lambda^\theta(\mathcal{F})$.

$$a) \quad \frac{1}{x!} \lambda^x \exp(-\lambda) = \frac{1}{x!} \exp(x \log \lambda) \exp(-\lambda)$$

$$= \frac{1}{x!} \exp(x \log \lambda - \lambda)$$

$$\implies a(x) = \frac{1}{x!} \mathbb{1}_{\mathbb{N}}(x) \quad , \quad \theta = \log \lambda \quad , \quad t(x) = x$$

Por lo tanto

$$\mu(\theta) = \log \int \frac{1}{x!} \mathbb{1}_{\mathbb{N}}(x) \exp(x \log \lambda) d\lambda$$

$$= \log \sum_{x=0}^{\infty} \frac{1}{x!} \lambda^x = \log e^\lambda = \lambda \quad \checkmark$$

b) Los elementos de $\mathcal{C}_\theta(\mathcal{F})$ son de la forma

$$p_\theta(\theta | s_0, n_0) = h(s_0, n_0) \exp \left\{ s_0 \theta - n_0 \overbrace{\mu(\theta)}^{\exp(\theta)} \right\} \quad (\text{cf p. 52})$$

\Rightarrow Como $\theta = \log \lambda$ &

$$p_{\lambda}^{\theta}(\lambda | s_0, n_0) = p_{\theta}(\theta(a) | s_0, n_0) | J_{\theta}(\lambda) |$$

$$= p_{\theta}(\log \lambda | s_0, n_0) \frac{1}{\lambda}$$

$$\propto \exp \{ s_0 \log \lambda - n_0 \lambda \} \frac{1}{\lambda}$$

$$= \exp \{ \log(\lambda^{s_0}) \} \exp \{ -n_0 \lambda \} \frac{1}{\lambda}$$

$$= \lambda^{s_0} \exp \{ -n_0 \lambda \} \lambda$$

$$= \lambda^{s_0-1} \exp \{ -n_0 \lambda \}$$

Así son los elementos de $C_a^{\theta}(\mathcal{F})$

c) También tenemos que $C_a(\mathcal{F})$ tiene

$$p_a(\lambda | s_0, n_0) \propto \lambda^{s_0} e^{-n_0 \lambda} \quad (\text{cf p60})$$

Poniendo $s_0 = \alpha - 1$ & $n_0 = \beta$ es claro que

$C_a(\mathcal{F})$ es la familia $\text{Gam}(\lambda | \alpha, \beta)$

d) Es consecuencia inmediata de b y c.

3. Sea $\mathbf{X} = \{X_1, \dots, X_n\}$ una muestra aleatoria de observaciones i.i.d. de una distribución Poisson, con función de probabilidad

$$\Pr[X = x | \lambda] = \frac{\lambda^x e^{-\lambda}}{x!} \quad (x = 0, 1, \dots; 0 < \lambda).$$

Sea X_* el valor de una observación futura de este modelo.

(a) Suponiendo una distribución inicial $\text{Gamma}(\lambda | \alpha, \beta)$ para λ , encuentra el valor esperado de la distribución final del parámetro $\phi = \phi(\lambda) = \Pr[X_* = 0 | \lambda]$.

(b) Encuentra la distribución predictiva final de X_* , dada por

$$\Pr[X_* = x_* | \mathbf{x}] = \int \Pr[X_* = x_* | \lambda] p(\lambda | \mathbf{x}) d\lambda,$$

donde $p(\lambda | \mathbf{x})$ denota a la función de densidad de la distribución final de λ . En particular, ¿cuál es el valor de $\Pr[X_* = 0 | \mathbf{x}]$?

(c) Compara (a) con (b). ¿Qué puedes decir sobre la probabilidad de que X_* sea igual a cero en cada caso?

$$\begin{aligned} a) \mathbb{E}[\phi | \mathbf{x}] &= \int \phi p(\phi | \mathbf{x}) d\phi \\ &= \int \Pr[X_* = 0 | \mathbf{x}] p(\phi | \mathbf{x}) d\phi \\ &= \int e^{-\lambda} p(\phi | \mathbf{x}) d\phi \\ &= e^{-\lambda} \end{aligned}$$

b) Primero calculamos

$$p(\lambda | \hat{x}) = \frac{p(\lambda) p(\hat{x} | \lambda)}{\int p(\lambda) p(\hat{x} | \lambda) d\lambda}$$

$$= \frac{\text{Gamma}(\lambda | \alpha, \beta) \frac{\lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}}{x_1! \dots x_n!}}{\int \text{Gamma}(\lambda | \alpha, \beta) \frac{\lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}}{x_1! \dots x_n!} d\lambda}$$

$$= \frac{\frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda} \frac{\lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}}{x_1! \dots x_n!}}{\int \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda} \frac{\lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}}{x_1! \dots x_n!} d\lambda}$$

$$= \frac{\lambda^{\alpha-1 + \sum_{i=1}^n x_i} e^{-(\beta+n)\lambda}}{\int \lambda^{\alpha-1 + \sum_{i=1}^n x_i} e^{-(\beta+n)\lambda} d\lambda}$$

$$= \frac{(\beta+n)^{\alpha + \sum_{i=1}^n x_i}}{\Gamma(\alpha + \sum_{i=1}^n x_i)} \lambda^{\alpha-1 + \sum_{i=1}^n x_i} e^{-(\beta+n)\lambda} = \text{Gamma}(\lambda | \alpha + \sum x_i, \beta+n)$$

Além n ,

$$\int Pr[X_n = x_n | \lambda] p(\lambda | \hat{x}) d\lambda =$$

$$\int \frac{\lambda^{x_n} e^{-\lambda}}{x_n!} \frac{(\beta+n)^{\alpha+\sum_{i=1}^n x_i}}{\Gamma(\alpha+\sum_{i=1}^n x_i)} \lambda^{\alpha-1+\sum_{i=1}^n x_i} e^{-(\beta+n)\lambda} d\lambda =$$

$$\frac{1}{x_n!} \frac{(\beta+n)^{\alpha+\sum_{i=1}^n x_i}}{\Gamma(\alpha+\sum_{i=1}^n x_i)} \int \lambda^{\alpha+x_n+\sum_{i=1}^n x_i-1} e^{-(\beta+n+1)\lambda} d\lambda =$$

$$\frac{1}{x_n!} \frac{(\beta+n)^{\alpha+\sum_{i=1}^n x_i}}{\Gamma(\alpha+\sum_{i=1}^n x_i)} \frac{\Gamma(\alpha+x_n+\sum_{i=1}^n x_i)}{(\beta+n+1)^{\alpha+x_n+\sum_{i=1}^n x_i}} =$$

$$\frac{(\beta+n)^{\alpha+\sum_{i=1}^n x_i}}{(\beta+n+1)^{\alpha+x_n+\sum_{i=1}^n x_i}}.$$

Ocupamos que

$$\frac{\Gamma(z+1)}{\Gamma(z)} = z$$

4. Desarrolla el ejemplo relativo a la distribución normal que vimos en clase (páginas 66 y 67 de las notas "Inferencia.pdf"). Específicamente,

(a) Muestra que la familia Normal/Gamma-inversa es conjugada para el modelo $N(x|\mu, \sigma^2)$, verificando la regla de actualización de los hiperparámetros vista en clase.

(b) Muestra que la distribución final marginal de μ es t de Student,

$$St(\mu|m_x, n_x a_x / b_x, a_x).$$

(c) Adicionalmente encuentra $p(y|x)$, la distribución predictiva final de la observación futura $Y = X_{n+1}$ para este modelo.

a) Primero veamos $p(\mu | \sigma^2, x) = N(\mu | m_x, \sigma^2 / n_x)$.

Por Bayes,

$$p(\mu | \sigma^2, x) \propto p(x | \mu, \sigma^2) p(\mu | \sigma^2)$$

$$= \left\{ \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) \right\} \times \frac{1}{\sqrt{2\pi(\sigma_0^2/n_0)}} \exp\left(-\frac{(\mu - m_0)^2}{2\frac{\sigma_0^2}{n_0}}\right)$$

$$\propto \exp\left\{-\frac{(\mu - m_0)^2}{2\sigma_0^2/n_0} - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}\right\}$$

$$\propto \exp\left\{-\frac{1}{2\sigma^2} \left[n_0(\mu - m_0)^2 + \sum_{i=1}^n (x_i - \mu)^2\right]\right\}$$

$$\propto \exp\left\{-\frac{1}{2\sigma^2} \left[n_0\mu^2 - 2n_0\mu m_0 + \sum_{i=1}^n (\mu^2 - 2\mu x_i)\right]\right\}$$

Los sumandos que no dependen de μ salen como factores constantes de la forma $\exp(\text{algo que no depende de } \mu)$.

$$\propto \exp\left\{-\frac{1}{2\sigma^2} \left[n_0\mu^2 - 2n_0\mu m_0 + n\mu^2 + 2\mu n\bar{x}\right]\right\} \dots (1)$$

por otro lado,

$$N(\mu | m_x, \sigma^2/n_x)$$

$$\propto \exp \left\{ -\frac{n_x(\mu - m_x)^2}{2\sigma^2} \right\}$$

$$\propto \exp \left\{ \frac{1}{2\sigma^2} (n_0 + n) \left(\mu - \frac{n_0 m_0 + n \bar{x}}{n_0 + n} \right)^2 \right\}$$

$$\propto \exp \left\{ \frac{1}{2\sigma^2} \frac{(\mu(n_0 + n) - n_0 m_0 + n \bar{x})^2}{n_0 + n} \right\}$$

$$\propto \exp \left\{ \frac{1}{2\sigma^2} \left[\frac{\mu^2(n_0 + n)^2}{n_0 + n} - \frac{2\mu(n_0 + n)n_0 m_0}{n_0 + n} + \frac{2\mu(n_0 + n)n\bar{x}}{n_0 + n} \right] \right\}$$

$$\propto \exp \left\{ \frac{1}{2\sigma^2} [\mu^2(n_0 + n) - 2\mu n_0 m_0 + 2\mu n \bar{x}] \right\}$$

Comparando esto con (1) vemos que coinciden y por lo tanto,

$$p(\mu | \sigma^2, x) = N(\mu | m_x, \sigma^2/n_x).$$

Ahora vemos que $p(\sigma^2 | x) = IGa(\sigma^2 | a_x/2, b_x/2)$.

Primero notemos que

$$p(x|\sigma^2) = \frac{p(x, \sigma^2)}{p(\sigma^2)} = \frac{\int p(x, \sigma^2, \mu) d\mu}{p(\sigma^2)}$$

$$= \frac{1}{p(\sigma^2)} \int p(x|\sigma^2, \mu) p(\sigma^2, \mu) d\mu$$

Por lo tanto,

$$p(\sigma^2|x) \propto p(\sigma^2) p(x|\sigma^2)$$

$$\propto \int p(x|\sigma^2, \mu) p(\sigma^2, \mu) d\mu$$

$$= \int N(x|\mu, \sigma^2) N(\mu|m_0, \sigma^2/n_0) \text{Ga}(\sigma^2|a_0/2, b_0/2) d\mu$$

$$= \int \left[\prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\} \right) \right.$$

$$\times \frac{1}{\sqrt{2\pi\sigma^2/n_0}} \exp \left\{ -\frac{(\mu - m_0)^2}{2\sigma^2/n_0} \right\}$$

$$\times \frac{(b_0/2)^{a_0/2}}{\Gamma(a_0/2)} (1/\sigma^2)^{a_0/2+1} \exp(-b_0/2) \Big] d\mu$$