

1. Considera el modelo Poisson($x|\lambda$).

- (a) Encuentra la distribución inicial no informativa de Jeffreys para λ , así como la distribución final correspondiente dada una muestra aleatoria de tamaño n .
- (b) ¿Qué relación guardan las distribuciones obtenidas en el inciso (a) con la familia conjugada mencionada en el inciso (c) del Problema 2 de la Tarea 3?

$$a) \text{ Poisson}(\hat{x}|\lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \frac{\lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}}{x_1! \cdots x_n!}.$$

Entonces

$$\log p(\hat{x}|\lambda) = \left(\sum_{i=1}^n x_i\right) \log \lambda + (-n\lambda) - \sum_{i=1}^n \log(x_i!).$$

Entonces

$$\frac{d}{d\lambda} \log p(\hat{x}|\lambda) = \left(\sum_{i=1}^n x_i\right) \frac{1}{\lambda} - n.$$

Entonces

$$\frac{d^2}{d\lambda^2} \log p(\hat{x}|\lambda) = -\frac{\sum_{i=1}^n x_i}{\lambda^2}.$$

Entonces

$$\begin{aligned} I(\lambda) &= \mathbb{E} \left[\frac{t}{\lambda^2} | \lambda \right] = \frac{1}{\lambda^2} \mathbb{E} \left[\sum_{i=1}^n x_i | \lambda \right] \\ &= \frac{1}{\lambda^2} \sum_{i=1}^n \mathbb{E} [x_i | \lambda] = \frac{1}{\lambda^2} n\lambda = \frac{n}{\lambda}. \end{aligned}$$

Por lo tanto, $\pi(\lambda) \propto \frac{1}{\lambda^{1/2}}.$

$$p(\lambda | \hat{x}) \propto \pi(\lambda) p(\hat{x} | \lambda)$$

$$\propto \frac{1}{\lambda^{1/2}} \lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}$$

$$= \lambda^{-\frac{1}{2} + \sum_{i=1}^n x_i} e^{-n\lambda}$$

$$\propto \text{Gamma} \left(\lambda \mid -\frac{1}{2} + \sum_{i=1}^n x_i, n \right)$$

b) Podríamos considerar $\pi(\lambda)$ como una $\text{Gamma}(\lambda \mid \alpha = 1/2, \beta = 0)$ pero recordando que se necesita $\alpha > 0, \beta > 0$ para que esta distribución sea propia.

2. Considera la distribución Exponencial, con función de densidad

$$p(x|\theta) = \theta e^{-\theta x} \quad (0 < x; 0 < \theta).$$

(a) Encuentra la distribución inicial de Jeffreys para θ . ¿Es una distribución propia?

(b) ¿Pertenece esta distribución a la familia conjugada mencionada en el inciso (a) del Problema 1 de la Tarea 3?

$$a) \quad p(\hat{x}|\theta) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n \exp\left(-\theta \sum_{i=1}^n x_i\right).$$

$$\text{Entonces} \quad \log p(\hat{x}|\theta) = n \log \theta - \theta \sum_{i=1}^n x_i.$$

$$\text{Entonces} \quad \frac{d}{d\theta} \log p(\hat{x}|\theta) = \frac{n}{\theta} - \theta$$

$$\text{Entonces} \quad \frac{d}{d\theta^2} \log p(\hat{x}|\theta) = -\frac{n}{\theta^2}.$$

$$\text{Entonces} \quad I(\theta) = \frac{n}{\theta^2}.$$

$$\text{Por lo tanto,} \quad \pi(\theta) \propto \frac{1}{\theta}.$$

Claramente esta distribución no es propia.

b) Podríamos considerar $\pi(\theta)$ como una Gamma $(0 \mid \alpha=0, \beta=0)$ pero recordando que no es propia.

3. Continuando con el ejercicio anterior:

- (a) Encuentra una aproximación normal asintótica para $p(\theta|\mathbf{x})$, la densidad de la distribución final conjugada obtenida en el inciso 1(a) de la Tarea 3.
- (b) Sea $\phi = \log(\theta)$. Encuentra $p_\phi(\phi|\mathbf{x})$, la correspondiente función de densidad para ϕ .
- (c) Encuentra una aproximación normal asintótica para $p_\phi(\phi|\mathbf{x})$.
- (d) ¿Cuál aproximación es mejor, la del inciso (a) o la del inciso (c)?
¿Por qué?

a) Recordemos que

$$p(\theta|\hat{\mathbf{x}}) \propto \theta^{\alpha'} \exp\{-\theta\beta'\}.$$

$$\text{donde } \alpha' = \alpha + n - 1 \quad \text{y} \quad \beta' := \beta + \sum_{i=1}^n x_i \implies$$

Entonces,

$$\frac{d}{d\theta} p(\theta|\hat{\mathbf{x}})$$

$$\propto \alpha' \theta^{\alpha'-1} \exp\{-\theta\beta'\} - \theta^{\alpha'} \exp\{-\theta\beta'\} \beta'$$

$$= \exp\{-\theta\beta'\} [\alpha' \theta^{\alpha'-1} - \beta' \theta^{\alpha'}]$$

$$\text{En particular, } \hat{\theta} = \frac{\alpha'}{\beta'}.$$

Par les ludo,

$$\log p(\theta | \hat{x}) = \log (\theta^{\alpha'} e^{-\theta \beta'}) = \alpha' \log \theta - \theta \beta'.$$

$$\text{Enfin, } \frac{d^2}{d\theta^2} \log p(\theta | \hat{x}) = - \frac{\alpha'}{\theta^2}.$$

$$\text{Par la suite, } V(\theta) = \frac{\theta^2}{\alpha'}.$$

$$\text{En particulier, } V(\hat{\theta}) = \frac{\alpha'}{(\beta')^2}.$$

Finalement,

$$p(\theta | \hat{x}) = N\left(\theta \mid \frac{\alpha'}{\beta'}, \frac{\alpha'}{(\beta')^2}\right) \{1 + o(n^{-1})\}.$$

$$\text{donc } \alpha' = \alpha + n - 1 \quad \text{et} \quad \beta' = \beta + \sum_{i=1}^n x_i.$$

b) Claramente, $\theta(\phi) = e^\phi$. Entonces

$$p_\phi(\phi | \hat{x}) = p(\theta(\phi) | \hat{x}) \frac{d}{d\phi} \theta(\phi)$$

$$\propto (e^\phi)^{\alpha'} e^{-e^\phi \beta'} e^\phi$$

$$= e^{\phi(\alpha'+1) - e^\phi \beta'}$$

c) Calculando directamente.

$$\frac{d}{d\phi} p_\phi(\phi | \hat{x}) = e^{\phi(\alpha'+1) - e^\phi \beta'} ((\alpha'+1) - e^\phi \beta')$$

$$\text{De donde, } \hat{\phi} = \log\left(\frac{\alpha'+1}{\beta'}\right)$$

Por otro lado,

$$\log p_\phi(\phi | \hat{x}) = \phi(\alpha'+1) - e^\phi \beta'.$$

$$\text{De donde, } \frac{d^2}{d\phi^2} \log p_\phi(\phi | \hat{x}) = -e^\phi \beta'.$$

Par le fait, $V(\phi) = (e^{\phi} \beta')^{-1}$.

En particulier, $V(\hat{\phi}) = \left(\frac{\alpha'+1}{\beta'} \beta' \right)^{-1} = \frac{1}{\alpha'+1}$.

Finalement,

$$p_{\phi}(\phi | \hat{x}) = N\left(\phi \mid \log\left(\frac{\alpha'+1}{\beta'}\right), \frac{1}{\alpha'+1}\right).$$

4. Sea $\mathbf{X} = \{X_1, \dots, X_n\}$ una muestra de observaciones i.i.d. de la distribución $\text{Poisson}(x|\lambda_1)$ y sea $\mathbf{Y} = \{Y_1, \dots, Y_n\}$ una muestra de observaciones i.i.d. de la distribución $\text{Poisson}(y|\lambda_2)$, donde tanto λ_1 como λ_2 son desconocidos. Supón que la distribución inicial de (λ_1, λ_2) está dada por

$$p(\lambda_1, \lambda_2) = p(\lambda_1) p(\lambda_2) = \text{Gamma}(\lambda_1 | a_1, b_1) \text{Gamma}(\lambda_2 | a_2, b_2)$$

- Encuentra $p(\lambda_1, \lambda_2 | \mathbf{x}, \mathbf{y})$, la distribución final correspondiente, suponiendo que las muestras \mathbf{X} y \mathbf{Y} son independientes.
- Supón ahora que el parámetro de interés es $\theta = \lambda_1/\lambda_2$. Encuentra su distribución final marginal, $p(\theta | \mathbf{x}, \mathbf{y})$.
- Finalmente, encuentra la aproximación de Laplace (forma exponencial) para la densidad final marginal de θ .
- ¿Cómo se comparan la densidad del inciso (b) y la aproximación del inciso (c)? Argumenta tu respuesta.

a) Por Bayes:

$$p(\lambda_1, \lambda_2 | \hat{\mathbf{x}}, \hat{\mathbf{y}}) \propto p(\hat{\mathbf{x}}, \hat{\mathbf{y}} | \lambda_1, \lambda_2) p(\lambda_1, \lambda_2)$$

$$= p(\hat{\mathbf{x}} | \lambda_1) p(\hat{\mathbf{y}} | \lambda_2) p(\lambda_1) p(\lambda_2)$$

$$\propto \left\{ \prod_{i=1}^n \lambda_1^{x_i} e^{-\lambda_1} \right\} \left\{ \prod_{i=1}^n \lambda_2^{y_i} e^{-\lambda_2} \right\} \\ \left\{ \lambda_1^{a_1-1} e^{-b_1 \lambda_1} \right\} \left\{ \lambda_2^{a_2-1} e^{-b_2 \lambda_2} \right\}$$

$$= \left\{ \lambda_1^{a_1-1 + \sum_{i=1}^n x_i} e^{-(n+b_1)\lambda_1} \right\} \left\{ \lambda_2^{a_2-1 + \sum_{i=1}^n y_i} e^{-(n+b_2)\lambda_2} \right\}$$

$$\propto \text{Ga}(\lambda_1 | a_1 + \sum_{i=1}^n x_i, n+b_1) \text{Ga}(\lambda_2 | a_2 + \sum_{i=1}^n y_i, n+b_2).$$

b) Consideremos la transformacion

$$(\lambda_1, \lambda_2) \xrightarrow{g} \left(\frac{\lambda_1}{\lambda_2}, \lambda_2 \right) = (\eta_1, \eta_2)$$

Entonces, $g^{-1}(\eta_1, \eta_2) = (\eta_1 \eta_2, \eta_2)$ y

$$\text{Jac}(g^{-1}) = \det \begin{pmatrix} \eta_2 & \eta_1 \\ 0 & 1 \end{pmatrix} = \eta_2.$$

Entonces,

$$p_{g(\lambda_1, \lambda_2)}(\hat{x}, \hat{y}) (\eta_1, \eta_2 | \hat{x}, \hat{y})$$

$$= p_{\lambda_1, \lambda_2 | \hat{x}, \hat{y}} \left(\underbrace{g^{-1}(\eta_1, \eta_2)}_{(\eta_1 \eta_2, \eta_2)} | \hat{x}, \hat{y} \right) |\text{Jac}(g^{-1})|$$

$$\propto \text{Ga}(\eta_1 \eta_2 | a_1 + \sum_{i=1}^n x_i, n + b_1) \text{Ga}(\eta_2 | a_2 + \sum_{i=1}^n y_i, n + b_2) \eta_2$$

Denotemos $a'_1 = a_1 + \sum_{i=1}^n x_i$, $b'_1 = n + b_1$ y

analogamente para a'_2 y b'_2 .

Entonces,

$$\text{Gamma}(\eta_1 \eta_2 \mid a'_1, b'_2) \text{Gamma}(\eta_2 \mid a'_2, b'_2) \eta_2$$

$$\propto (\eta_1 \eta_2)^{a'_1-1} e^{-b'_1(\eta_1 \eta_2)} \eta_2^{a'_2-1} e^{-b'_2 \eta_2} \eta_2$$

$$= \eta_1^{a'_1-1} \eta_2^{a'_1+a'_2-1} e^{-(b'_1 \eta_1 + b'_2) \eta_2}$$

$$= \eta_1^{a'_1-1} \text{Gamma}(\eta_2 \mid a'_1+a'_2, b'_1 \eta_1 + b'_2)$$

Integrando respecto de η_2 obtenemos

$$\eta_1^{a'_1-1} \frac{\Gamma(a'_1+a'_2)}{(b'_1 \eta_1 + b'_2)^{a'_1+a'_2}}$$

Pero $\eta_1 = 0$ y por lo tanto

$$p(\theta \mid \hat{x}, \hat{y}) \propto \frac{0^{a'_1-1}}{(b'_1 0 + b'_2)^{a'_1+a'_2}}.$$

c) En el inciso anterior vimos que

$$p_{\eta_1, \eta_2 | \hat{x}, \hat{y}}(\eta_1, \eta_2 | \hat{x}, \hat{y}) \propto \eta_1^{a'_1 - 1} \eta_2^{a'_1 + a'_2 - 1} e^{-(b'_1 \eta_1 + b'_2) \eta_2}$$

Queremos aproximar

$$p(\eta_1 | \hat{x}, \hat{y}) = \int p_{\eta_1, \eta_2 | \hat{x}, \hat{y}}(\eta_1, \eta_2 | \hat{x}, \hat{y}) d\eta_2$$
$$\propto \eta_1^{a'_1 - 1} \underbrace{\int \eta_2^{a'_1 + a'_2 - 1} e^{-(b'_1 \eta_1 + b'_2) \eta_2} d\eta_2}$$

Definimos

Vamos a aproximar esta integral.

$$h(\eta_1, \eta_2) := -(a'_1 + a'_2 - 1) \log \eta_2 + (b'_1 \eta_1 + b'_2) \eta_2$$

Entonces,

$$\frac{\partial}{\partial \eta_2} h(\eta_1, \eta_2) = -\frac{a'_1 + a'_2 - 1}{\eta_2} + (b'_1 \eta_1 + b'_2)$$

$$\text{Entonces } \hat{\eta}_2 = \frac{a'_1 + a'_2 - 1}{b'_1 \eta_1 + b'_2} \quad y$$

$$h(\eta_1, \hat{\eta}_2) = -(a'_1 + a'_2 - 1) \log \left(\frac{a'_1 + a'_2 - 1}{b'_1 \eta_1 + b'_2} \right) + (a'_1 + a'_2 - 1),$$

$$\exp \{ -h(\eta_1, \hat{\eta}_2) \} = \left(\frac{a'_1 + a'_2 - 1}{b'_1 \eta_1 + b'_2} \right)^{(a'_1 + a'_2 - 1)} \exp \{ -(a'_1 + a'_2 - 1) \}.$$

$$\text{Max}_{\eta_2}, \quad \frac{\partial^2}{\partial \eta_2^2} h(\eta_1, \eta_2) = \frac{a'_1 + a'_2 - 1}{\eta_2^2}.$$

Por lo tanto,

$$\Sigma(\hat{\eta}_2) = \frac{\hat{\eta}_2^2}{a'_1 + a'_2 - 1} = \frac{a'_1 + a'_2 - 1}{(b'_1 \eta_1 + b'_2)^2}.$$

Entonces

$$\hat{I} = (\eta_1)^{1/2} |\Sigma(\hat{\eta}_2)|^{1/2} \exp \{ -h(\hat{\eta}_2) \}.$$

$$= (\eta_1)^{1/2} \frac{(a'_1 + a'_2 - 1)^{1/2}}{b'_1 \eta_1 + b'_2} \left(\frac{a'_1 + a'_2 - 1}{b'_1 \eta_1 + b'_2} \right)^{(a'_1 + a'_2 - 1)} \exp \{ -(a'_1 + a'_2 - 1) \}$$

$$\propto \frac{1}{(b'_1 \eta_1 + b'_2)^{a'_1 + a'_2}}.$$

d) La aproximación es exacta (basta comparar).