

1. En un problema de decisión estadístico con función de utilidad $u(a, \theta)$, considera la función de utilidad alternativa $u_A(a, \theta) = A u(a, \theta) + B(\theta)$, donde A es una constante positiva y $B(\theta)$ es una función acotada de θ .

Demuestra que $u(a, \theta)$ y $u_A(a, \theta)$ son equivalentes, en el sentido de que llevan a la misma decisión óptima.

Calculando directamente,

$$\mathbb{E} [u_A(a, \theta) | x] =$$

$$\mathbb{E} [A u(a, \theta) + B(\theta) | x] =$$

$$A \mathbb{E} [u(a, \theta) | x] + \mathbb{E} [B(\theta) | x].$$

Donde $\mathbb{E} [B(\theta) | x]$ existe porque $B(\theta)$ es acotada.

Por lo tanto, como $A > 0$,

$$\max_{a \in A} \mathbb{E} [u_A(a, \theta) | x] = \max_{a \in A} \mathbb{E} [u(a, \theta) | x].$$

2. Demuestra que la función de puntaje cuadrática

$$s(\mathbf{q}, E_j) = A \left\{ 2q_j - \sum_{i=1}^k q_i^2 \right\} + B \quad (A > 0; j = 1, 2, \dots, k)$$

es propia. (Nota que no es local.)

Para todos $\ell, i \in \{1, \dots, k\}$,

$$\begin{aligned} \frac{\partial}{\partial q_\ell} s(q, \bar{e}_i) &= \frac{\partial}{\partial q_\ell} \left(A \left\{ 2q_i - \sum_{j=1}^k q_j^2 \right\} + B \right) \\ &= A \{ 2\delta_{i\ell} - 2q_\ell \}. \end{aligned}$$

Entonces

$$\begin{aligned} \frac{\partial}{\partial q_\ell} \left(\sum_{i=1}^k s(q, \bar{e}_i) p_i \right) &= \\ \sum_{i=1}^k A \{ 2\delta_{i\ell} - 2q_\ell \} p_i &= \\ 2A \left(\sum_{i=1}^k \delta_{i\ell} p_i - \sum_{i=1}^k q_\ell p_i \right) &= \\ 2A(p_\ell - q_\ell). \end{aligned}$$

∴ Igualando a 0 obtenemos $p_\ell = q_\ell$.

Mas aun,

$$\frac{\partial^2}{\partial q_m \partial q_\ell} \left(\sum_{j=1}^k s(q, \epsilon_j) p_j \right) = \frac{\partial}{\partial q_m} (2A(p_\ell - q_\ell)) = -2A \delta_{lm}$$

Entonces

$$\frac{\partial^2}{\partial q^2} \left(\sum_{j=1}^k s(q, \epsilon_j) p_j \right) = -2A I_k$$

es definida negativa y por lo tanto el punto

en que $q = p$ es maximo.

3. Supón que se requiere una predicción puntual de la variable aleatoria (real y continua) $Y = X_{n+1}$ después de haber observado la muestra $\mathbf{x} = (x_1, \dots, x_n)$. Plantea este problema como un problema de decisión estadístico usando la función de pérdida

$$L(\hat{y}, y) = k_1(y - \hat{y}) I_{(-\infty, y)}(\hat{y}) + k_2(\hat{y} - y) I_{[y, \infty)}(\hat{y}),$$

donde $I_C(\cdot)$ denota a la función indicadora del conjunto C , y k_1 y k_2 son constantes positivas. Demuestra que el predictor óptimo \hat{y}_* es el cuantil de orden $q = k_1/(k_1 + k_2)$ de la distribución predictiva $p(y|\mathbf{x})$.

Calculando directamente,

$$\begin{aligned} L_x^*(\hat{y}) &= \int_{-\infty}^{\infty} L(\hat{y}, y) p(y|\mathbf{x}) dy \\ &= \int_{-\infty}^{\infty} [k_1(y - \hat{y}) I_{(-\infty, y)}(\hat{y}) + k_2(\hat{y} - y) I_{[y, \infty)}(\hat{y})] p(y|\mathbf{x}) dy \\ &= \int_{-\infty}^{\infty} [k_1(y - \hat{y}) I_{(\hat{y}, \infty)}(y) + k_2(\hat{y} - y) I_{(-\infty, \hat{y})}(y)] p(y|\mathbf{x}) dy \\ &= \int_{\hat{y}}^{\infty} k_1(y - \hat{y}) p(y|\mathbf{x}) dy + \int_{-\infty}^{\hat{y}} k_2(\hat{y} - y) p(y|\mathbf{x}) dy \end{aligned}$$

Entonces (derivando bajo el signo de la integral)

$$\begin{aligned} \frac{d}{d\hat{y}} L_x^*(\hat{y}) &= -k_1 \int_{\hat{y}}^{\infty} p(y|\mathbf{x}) dy + k_2 \int_{-\infty}^{\hat{y}} p(y|\mathbf{x}) dy \\ &= -k_1 + (k_1 + k_2) \int_{-\infty}^{\hat{y}} p(y|\mathbf{x}) dy \end{aligned}$$

Donde la ultima igualdad es porque

$$\int_{\hat{y}^*}^{\infty} p(y|x) dy = \left(1 - \int_{-\infty}^{\hat{y}^*} p(y|x) dy \right)$$

Igualando a 0 y despejando obtenemos

$$\int_{-\infty}^{\hat{y}^*} p(y|x) dy = \frac{k_1}{k_1 + k_2}.$$

Mas aun, por el TFC

$$\frac{d^2}{d\hat{y}^2} L_x(\hat{y}) = (k_1 + k_2) p(\hat{y}|x) > 0$$

y por lo tanto \hat{y}^* es minimo.

4. Supón que $\mathbf{X} = \{X_1, \dots, X_n\}$ es una muestra aleatoria de una distribución $p(x|\theta)$, con $\theta > 0$, y sea $p(\theta)$ la distribución inicial de θ . Estos elementos dan lugar a $p(\theta|\mathbf{x})$, la distribución final de θ .

Considera ahora la siguiente familia de funciones de pérdida para la estimación puntual de θ , vista como un problema de decisión estadístico:

$$L(\hat{\theta}, \theta) = \frac{(\hat{\theta} - \theta)^2}{\hat{\theta}^r \theta^s}; \quad \text{donde } r, s = 0, 1, 2.$$

Encuentra el estimador bayesiano óptimo de θ .

$$\begin{aligned} L_x^*(\hat{\theta}) &= \int_{\Theta} L(\hat{\theta}, \theta) f(\theta | \mathbf{x}) d\theta \\ &= \int_{\Theta} (\hat{\theta} - \theta)^2 \hat{\theta}^{-r} \theta^{-s} f(\theta | \mathbf{x}) d\theta \end{aligned}$$

Entonces, derivando sobre el signo de la integral

$$\begin{aligned} \frac{d}{d\hat{\theta}} L_x^*(\hat{\theta}) &= \\ \int_{\Theta} \left[2(\hat{\theta} - \theta) \hat{\theta}^{-r} + (\hat{\theta} - \theta)^2 (-r) \hat{\theta}^{-r-1} \right] \theta^{-s} f(\theta | \mathbf{x}) d\theta &= \\ \int_{\Theta} \left[2\hat{\theta}^{-r+1} - 2\theta\hat{\theta}^{-r} - r\hat{\theta}^{-r+1} + 2r\hat{\theta}^{-r}\theta - r\theta^2\hat{\theta}^{-r-1} \right] \theta^{-s} f(\theta | \mathbf{x}) d\theta &= \\ \hat{\theta}^{-r-1} \int_{\Theta} \left[2\hat{\theta}^2 - 2\theta\hat{\theta} - r\hat{\theta}^2 + 2r\hat{\theta}\theta - r\theta^2 \right] \theta^{-s} f(\theta | \mathbf{x}) d\theta & \end{aligned}$$

Igualando a 0 o (menos)

$$\begin{aligned}
0 &= \int_{\mathbb{H}} 2\hat{\theta}^2 \theta^{-s} p(\theta|x) d\theta - \int_{\mathbb{H}} 2\hat{\theta}\theta^{-s+1} p(\theta|x) d\theta \\
&\quad - \int_{\mathbb{H}} r\hat{\theta}^2 \theta^{-s} p(\theta|x) d\theta + \int_{\mathbb{H}} 2r\hat{\theta}\theta^{-s+1} p(\theta|x) d\theta \\
&\quad - \int_{\mathbb{H}} r\theta^{-s+2} p(\theta|x) d\theta \\
&= \hat{\theta}^2 (2-r) \int_{\mathbb{H}} \theta^{-s} p(\theta|x) d\theta + \\
&\quad \hat{\theta} (2r-2) \int_{\mathbb{H}} \theta^{-s+1} p(\theta|x) d\theta - \\
&\quad r \int_{\mathbb{H}} \theta^{-s+2} p(\theta|x) d\theta \\
&= \hat{\theta}^2 (2-r) \mathbb{E} [\theta^{-s} | x] + \\
&\quad \hat{\theta} (2r-2) \mathbb{E} [\theta^{-s+1} | x] - \\
&\quad r \mathbb{E} [\theta^{-s+2} | x]
\end{aligned}$$

Resolvendo esta equação quadrática em $\hat{\theta}$
obtemos o desejado.

5. Invarianza.

- a) Calcula $\delta(\hat{\theta}, \theta)$, $\Delta_\theta(\hat{\theta})$ y $\hat{\theta}_*$, así como $\delta_\mu(\hat{\mu}, \mu)$, $\Delta_\mu(\hat{\mu})$ y $\hat{\mu}_*$, para el caso de la distribución exponencial (ver páginas 62 y 63 de las notas "Inferencia.pdf", correspondientes a la Sección 3 del temario). ¿Se cumple que $\hat{\mu}_* = \mu(\hat{\theta}_*)$?
- (b) Calcula también $E[\theta|\mathbf{x}]$ y $E[\mu|\mathbf{x}]$ y nota que $E[\mu|\mathbf{x}] \neq \mu(E[\theta|\mathbf{x}])$.
- (c) ¿Qué puedes decir de estos resultados?

a) Calculando directamente,

$$\begin{aligned}
 \delta(\hat{\theta}, \theta) &= \int_0^\infty p(x|\theta) \log \left\{ \frac{p(x|\hat{\theta})}{p(x|\theta)} \right\} dx \\
 &= \int_0^\infty \theta e^{-\theta x} \log \left\{ \frac{\theta e^{-\theta x}}{\hat{\theta} e^{-\hat{\theta} x}} \right\} dx \\
 &= \int_0^\infty \theta e^{-\theta x} \left(\log \left(\frac{\theta}{\hat{\theta}} \right) + (-\theta x + \hat{\theta} x) \right) dx \\
 &= \int_0^\infty \theta e^{-\theta x} \log \left(\frac{\theta}{\hat{\theta}} \right) dx + \int_0^\infty \theta e^{-\theta x} (-\theta + \hat{\theta}) x dx \\
 &= \log \left(\frac{\theta}{\hat{\theta}} \right) + (-\theta + \hat{\theta}) \frac{1}{\theta} \\
 &= \log \left(\frac{\theta}{\hat{\theta}} \right) + \frac{\hat{\theta}}{\theta} - 1 .
 \end{aligned}$$

Donde la penúltima igualdad se cumple porque

$$\int_0^\infty \theta e^{-\theta x} dx = 1 \quad \& \quad \int_0^\infty x e^{-\theta x} dx = \frac{1}{\theta^2}.$$

Luego,

$$\Delta_0(\hat{\theta}) = E[\delta(\hat{\theta}, \theta) | x]$$

$$= E\left[\log\left(\frac{\theta}{\hat{\theta}}\right) + \frac{\hat{\theta}}{\theta} - 1 | x\right]$$

$$= E[\log \theta | x] + \hat{\theta} E\left[\frac{1}{\theta} | x\right] - \log \hat{\theta} - 1$$

Pero

$$E\left[\frac{1}{\theta} | x\right] = \int_0^\infty \frac{1}{\theta} p(\theta | x) d\theta$$

$$= \int_0^\infty \frac{1}{\theta} \frac{b_x^{a_x}}{\Gamma(a_x)} \theta^{a_x-1} e^{-b_x \theta} d\theta$$

$$= \frac{b_x^{a_x}}{\Gamma(a_x)} \int_0^\infty \theta^{a_x-2} e^{-b_x \theta} d\theta$$

$$= \frac{b_x^{a_x}}{\Gamma(a_x)} \frac{\Gamma(a_x-1)}{b_x^{a_x-1}} = \frac{b_x}{a_x-1}.$$

De donde,

$$\Delta_0(\hat{\theta}) =$$

$$\mathbb{E} \left[\log \theta | x \right] + \hat{\theta} \mathbb{E} \left[\frac{1}{\theta} | x \right] - \log \hat{\theta} - 1 =$$

$$\mathbb{E} \left[\log \theta | x \right] + \hat{\theta} \frac{b_x}{a_x - 1} - \log \hat{\theta} - 1.$$

Luego,

$$\frac{d}{d\hat{\theta}} \Delta_0(\hat{\theta}) = \frac{b_x}{a_x - 1} - \frac{1}{\hat{\theta}}$$

(igualando a 0 y despejando $\hat{\theta}$)

$$\hat{\theta}_* = \frac{a_x - 1}{b_x}.$$

Mas aun, como $\frac{d^2}{d\hat{\theta}^2} \Delta_0(\hat{\theta}) = \frac{1}{\hat{\theta}^2} > 0$,

entonces $\hat{\theta}_*$ es minimo.

Per se en la otra, como

$$S(\hat{\theta}, \theta) = \log\left(\frac{\hat{\theta}}{\theta}\right) + \frac{\hat{\theta}}{\theta} - 1.$$

Entonces,

$$\delta_\mu(\hat{\mu}, \mu) = \log\left(\frac{\hat{\mu}}{\mu}\right) + \frac{\hat{\mu}}{\hat{\mu}} - 1.$$

ADEMÁS

$$\begin{aligned} p_\mu(\mu | x) &= p(\theta(\mu) | x) |\mathcal{J}_\theta(\mu)| \quad (\theta(\mu) = \frac{1}{\mu}) \\ &= \frac{b_x^{a_x}}{\Gamma(a_x)} \left(\frac{1}{\mu}\right)^{a_x-1} e^{-b_x(1/\mu)} \left| -\frac{1}{\mu^2} \right| \\ &= \frac{b_x^{a_x}}{\Gamma(a_x)} \mu^{-(a_x+1)} e^{-b_x(1/\mu)} \end{aligned}$$

De donde,

$$\Delta_\mu(\hat{\mu}) = E_{\hat{\mu}} [\delta_\mu(\hat{\mu}, \mu) | x]$$

$$= \mathbb{E} \left[\log \left(\frac{\hat{\mu}}{\mu} \right) + \frac{\mu}{\hat{\mu}} - 1 \mid x \right]$$

$$= \log \hat{\mu} - \mathbb{E} [\log \mu \mid x] + \frac{1}{\hat{\mu}} \mathbb{E} [\mu \mid x] - 1$$

Rew

$$\mathbb{E} [\mu \mid x] = \int_0^\infty \mu p_\mu(\mu \mid x) d\mu$$

$$= \int_0^\infty \mu \frac{b_x^{ax}}{\Gamma(ax)} \mu^{-ax-1} e^{-bx(1/\mu)} d\mu$$

$$= \frac{b_x^{ax}}{\Gamma(ax)} \int_0^\infty \mu^{-ax} e^{-bx(1/\mu)} d\mu$$

$$= \frac{b_x^{ax}}{\Gamma(ax)} \frac{\Gamma(ax-1)}{b_x^{ax-1}} = \frac{b_x}{ax-1} \quad \dots (1)$$

De donde

$$\Delta_\mu(\hat{\mu}) = \log \hat{\mu} - \mathbb{E} [\log \mu \mid x] + \frac{1}{\hat{\mu}} \mathbb{E} [\mu \mid x] - 1$$

$$= \log \hat{\mu} - \mathbb{E} [\log \mu \mid x] + \frac{1}{\hat{\mu}} \frac{b_x}{ax-1} - 1$$

Luego, derivando obtenemos

$$\frac{d}{d\hat{\mu}} \Delta_{\mu}(\hat{\mu}) = \frac{1}{\hat{\mu}} - \frac{1}{\hat{\mu}^2} \frac{b_x}{a_x - 1}.$$

Igualando a 0 y despejando obtenemos

$$\hat{\mu}_* = \frac{b_x}{a_x - 1} = \mu(\hat{\theta}_*).$$

b) Calculando directamente

$$\mathbb{E}[\theta|x] = \int_0^\infty \theta p(\theta|x) d\theta$$

$$= \int_0^\infty \theta \frac{b_x^{a_x}}{\Gamma(a_x)} \theta^{a_x-1} e^{-b_x \theta} d\theta$$

$$= \frac{b_x^{a_x}}{\Gamma(a_x)} \int_0^\infty \theta^{a_x} e^{-b_x \theta} d\theta$$

$$= \frac{b_x^{a_x}}{\Gamma(a_x)} \frac{\Gamma(a_x+1)}{b_x^{a_x+1}} = \frac{a_x}{b_x}$$

Y ya habíamos visto en (i) que $\mathbb{E}[\mu|x] = \frac{b_x}{a_x - 1}$.

6. Sea X_1, X_2, \dots, X_n una muestra de variables aleatorias i.i.d. de una distribución exponencial $\text{Exp}(x|\theta)$, parametrizada de manera que $E(X|\theta) = 1/\theta$.

- a) Utilizando una función de pérdida cuadrática con respecto a $1/\theta$, es decir,

$$L(\hat{\theta}, \theta) = (\hat{\theta}^{-1} - \theta^{-1})^2$$

y suponiendo una distribución inicial conjugada para θ , encuentra el estimador bayesiano óptimo de θ .

- b) Dado que θ es un parámetro de escala, podría ser más apropiado utilizar una función de pérdida que sea invariante ante cambios de escala. Encuentra el estimador bayesiano óptimo de θ , utilizando ahora la función de pérdida

$$L^*(\hat{\theta}, \theta) = \theta^2 (\hat{\theta}^{-1} - \theta^{-1})^2$$

y suponiendo, al igual que antes, una distribución inicial conjugada para θ .

a) Como supusimos una distribución inicial conjugada para $\theta \implies \theta \sim \text{Gamma}(\alpha, \beta)$
 p.a. $\alpha, \beta > 0$. Mas aún,

$$\rho(\theta|x) = \frac{\theta^{\alpha_x}}{\Gamma(\alpha_x)} \theta^{\alpha_x-1} e^{-\beta \theta}. \quad (\text{cf. p 62 "Inferencia"})$$

Con $\alpha_x = n + \alpha$, $\beta_x = b + \sum_{i=1}^n x_i$. Calculando directamente.

$$L_x^*(\hat{\theta}) = \int_0^\infty L(\hat{\theta}, \theta) \rho(\theta|x) d\theta$$

$$= \int_0^\infty (\hat{\theta}^{-1} - \theta^{-1})^2 \frac{\theta^{\alpha_x}}{\Gamma(\alpha_x)} \theta^{\alpha_x-1} e^{-\beta_x \theta} d\theta$$

$$= \frac{\theta^{\alpha_x}}{\Gamma(\alpha_x)} \int_0^\infty \left(\frac{1}{\theta^2} - \frac{2}{\hat{\theta}\theta} + \frac{1}{\hat{\theta}^2} \right) \theta^{\alpha_x-1} e^{-\beta_x \theta} d\theta$$

$$= \frac{b_x^{\alpha_x}}{\Gamma(\alpha_x)} \int_0^\infty (\theta^{\alpha_x-3} e^{-b_x\theta} - \frac{2}{\hat{\theta}} \theta^{\alpha_x-2} e^{-b_x\theta} + \frac{1}{\hat{\theta}^2} \theta^{\alpha_x-1} e^{-b_x\theta}) d\theta$$

$$= \frac{b_x^{\alpha_x}}{\Gamma(\alpha_x)} \int_0^\infty \theta^{\alpha_x-3} e^{-b_x\theta} d\theta$$

$$- \frac{b_x^{\alpha_x}}{\Gamma(\alpha_x)} \frac{2}{\hat{\theta}} \int_0^\infty \theta^{\alpha_x-2} e^{-b_x\theta} d\theta$$

$$+ \frac{b_x^{\alpha_x}}{\Gamma(\alpha_x)} \frac{1}{\hat{\theta}^2} \int_0^\infty \theta^{\alpha_x-1} e^{-b_x\theta} d\theta$$

$$= \frac{b_x^{\alpha_x}}{\Gamma(\alpha_x)} \frac{\Gamma(\alpha_x-2)}{b_x^{\alpha_x-2}}$$

$$- \frac{2}{\hat{\theta}} \frac{b_x^{\alpha_x}}{\Gamma(\alpha_x)} \frac{\Gamma(\alpha_x-1)}{b_x^{\alpha_x-1}} + \frac{1}{\hat{\theta}^2}$$

$$= \frac{b_x^2}{(\alpha_x-1)(\alpha_x-2)} - \frac{2}{\hat{\theta}} \frac{b_x}{\alpha_x-1} + \frac{1}{\hat{\theta}^2}$$

Demandando respecto de $\hat{\theta}$ obtenemos

$$\frac{d}{d\hat{\theta}} L_x^*(\hat{\theta}) = \frac{2}{\hat{\theta}^2} \frac{b_x}{\alpha_x-1} - \frac{2}{\hat{\theta}^3}$$

Ligualando a 0 y despejando obtenemos $\hat{\theta}_* = \frac{\alpha_x-1}{b_x}$.

Demandando de nuevo y evaluando en $\hat{\theta}_*$ vemos que es min.

b) Procediendo de la misma manera que en el
mismo apartado es fácil ver que

$$\begin{aligned}
 L_x^*(\hat{\theta}) &= \int_0^\infty L(\hat{\theta}, \theta) p(\theta|x) d\theta \\
 &= \int_0^\infty \theta^2 (\hat{\theta}^{-1} - \theta^{-1})^2 \frac{b_x^{a_x}}{\Gamma(a_x)} \theta^{a_x-1} e^{-b_x \theta} d\theta \\
 &= \frac{b_x^{a_x}}{\Gamma(a_x)} \int_0^\infty \theta^{a_x-1} e^{-b_x \theta} d\theta \\
 &\quad - \frac{b_x^{a_x}}{\Gamma(a_x)} \frac{2}{\hat{\theta}} \int_0^\infty \theta^{a_x} e^{-b_x \theta} d\theta \\
 &\quad + \frac{b_x^{a_x}}{\Gamma(a_x)} \frac{1}{\hat{\theta}^2} \int_0^\infty \theta^{a_x+1} e^{-b_x \theta} d\theta \\
 &= 1 - \frac{2}{\hat{\theta}} \frac{b_x^{a_x}}{\Gamma(a_x)} \frac{\Gamma(a_x+1)}{b_x^{a_x+1}} + \frac{1}{\hat{\theta}^2} \frac{b_x^{a_x}}{\Gamma(a_x)} \frac{\Gamma(a_x+2)}{b_x^{a_x+2}} \\
 &= 1 - \frac{2}{\hat{\theta}} \frac{a_x}{b_x} + \frac{1}{\hat{\theta}^2} \underbrace{\frac{(a_x+1)a_x}{b_x^2}}
 \end{aligned}$$

Derivando

$$\frac{d}{d\hat{\theta}} L_x^*(\hat{\theta}) = \frac{2}{\hat{\theta}^2} \frac{a_x}{b_x} - \frac{2}{\hat{\theta}^3} \frac{(a_x+1)a_x}{b_x^2}.$$

Igualando a 0 y despejando obtenemos $\hat{\theta}_* = \frac{a_x + 1}{b_x}$.

Derivando de mas y evaluando en $\hat{\theta}_*$ vemos que es min.

c) Recordemos que $a_x = a + n$. Por lo tanto,

$$\frac{\frac{a_x - 1}{b_x}}{\frac{a_x + 1}{b_x}} = \frac{a+n-1}{a+n+1} \xrightarrow{n \rightarrow \infty} 1$$

En este sentido, asintoticamente son igual de buenas.

7. Sea $\mathbf{X} = \{X_1, \dots, X_n\}$ una muestra aleatoria de observaciones independientes con distribución desconocida $f(x)$. Supón que $f(x)$ sólo puede ser uno de los siguientes modelos paramétricos:

$$\mathcal{M}_1 : f(x) = p_1(x|\theta_1), \quad \theta_1 \in \Theta_1; \text{ con distribución inicial } p_1(\theta_1), \text{ propia;}$$

$$\mathcal{M}_2 : f(x) = p_2(x|\theta_2), \quad \theta_2 \in \Theta_2; \text{ con distribución inicial } p_2(\theta_2), \text{ propia.}$$

Supón también que, *a priori*, se considera que estos dos modelos son igualmente probables. El problema consiste en seleccionar uno de ellos.¹

Sea μ una variable dicotómica que indica cuál de los dos modelos es el correcto. Entonces podemos escribir

$$f(x) = p(x|\theta_\mu, \mu) = \begin{cases} p_1(x|\theta_1) & \text{si } \mu = 1 \\ p_2(x|\theta_2) & \text{si } \mu = 2 \end{cases}$$

Dado que el valor de μ es desconocido, podemos considerarlo un parámetro más en este modelo extendido.

- (a) Encuentra $p(\mathbf{x}|\mu)$ y, por lo tanto, la función de verosimilitud de μ ;
- (b) Encuentra la distribución final de μ .
- (c) Supón ahora que se desea contrastar las hipótesis

$$H_1 : \mu = 1 \quad \text{vs} \quad H_2 : \mu = 2$$

con base en la función de utilidad

$$u(\text{"Elegir } H_i\text{"}, \text{" } H_j \text{ es cierta"}) = I(i = j), \quad i, j = 1, 2,$$

donde $I(\cdot)$ denota la función indicadora. ¿Cuál es la regla de decisión para este problema?

a) Calculando directamente,

$$\begin{aligned} p(\mathbf{x}|\mu) &= \int_{\Theta_\mu} p(\mathbf{x}, \theta_\mu | \mu) d\theta_\mu \\ &= \int_{\Theta_\mu} p(\mathbf{x} | \theta_\mu, \mu) p(\theta_\mu | \mu) d\theta_\mu \\ &= \int_{\Theta_\mu} p(\mathbf{x} | \theta_\mu) p_\mu(\theta_\mu) d\theta_\mu \end{aligned}$$

b) Claramente,

$$p(\mathbf{x}) = p(\mathbf{x} | \mu=1) p(\mu=1) + p(\mathbf{x} | \mu=2) p(\mu=2)$$

$$= \frac{1}{2} \left(p(x|\mu=1) + p(x|\mu=2) \right)$$

pues $p(\mu=i) = 1/2$, $i=1,2$. Entonces,

$$p(\mu|x) = \frac{p(x|\mu) p(\mu)}{p(x)}$$

$$= \frac{p(x|\mu)}{p(x|\mu=1) + p(x|\mu=2)}.$$

c) Calculando directamente

$$\bar{u}(a_1) = \underbrace{u(a_1, \epsilon_1)}_1 p_r(\epsilon_1|x) + \underbrace{u(a_1, \epsilon_2)}_0 p_r(\epsilon_2|x)$$

$$= p_r(\epsilon_1|x) = p(\mu=1|x)$$

$$= \frac{p(x|\mu=1)}{p(x|\mu=1) + p(x|\mu=2)}.$$

∴ Rechazamos H_1 si $p(x|\mu=1) < p(x|\mu=2)$.

8. El problema de "clasificación supervisada" es un problema de decisión estadístico. Supongamos que tenemos una muestra de n observaciones $(X_1, G_1), (X_2, G_2), \dots, (X_n, G_n)$, donde cada $G_i \in \{1, 2, \dots, K\}$ indica que la observación $X_i \in \mathbb{R}_+$ pertenece a uno de K grupos distintos. Supongamos ahora que

$$p(x|G=g) = \text{Gamma}(x|\alpha_g, \beta_g) \quad (g = 1, 2, \dots, K)$$

y que

$$\Pr(G=g) = 1/K,$$

donde $\alpha_g > 0$ y $\beta_g > 0$ son parámetros conocidos.

El problema de clasificación consiste en lo siguiente: dada una nueva observación $X_* = x_*$, determinar de cuál de los K grupos proviene. Desde el punto de vista estadístico, el problema es entonces predecir el valor de G_* asociado con X_* .

- (a) Plantea y resuelve este problema como un problema de decisión, usando la función de pérdida

$$L(g_*, g) = 0 \quad (\text{si } g_* = g)$$

$$L(g_*, g) = 1 \quad (\text{si } g_* \neq g).$$

- (b) ¿Cómo se resolvería este problema si los valores de los parámetros $\beta_1, \beta_2, \dots, \beta_K$ fueran desconocidos?

a) Calculando directamente

$$\begin{aligned} L_x^*(g_*) &= \sum_{g=1}^K L(g_*, g) p(g|x) \\ &= \sum_{g \neq g_*} p(g|x) \\ &= 1 - p(g_*|x). \end{aligned}$$

$$\text{Entonces, } \hat{g}_* = \arg \max_{g_*} p(g_*|x) = \text{moda } p(g_*|x)$$

De hecho, en este caso $p(g_*|x) \propto p(x|g_*) p(g_*)$

$$x \quad p(x|g_*) = \text{Gamma}(x|\alpha_{g_*}, \beta_{g_*}).$$