

## El método de máxima verosimilitud y la divergencia de Kullback-Leibler

## Divergencia de Kullback-Leibler

Si  $f$  y  $g$  son FDP's denotamos por

$$D_{\text{KL}}(f, g) := \int f(x) \log \frac{f(x)}{g(x)} dx$$

a la divergencia de Kullback-Leibler entre  $f$  y  $g$ .

## Divergencia de Kullback-Leibler

Si  $f$  y  $g$  son FDP's denotamos por

$$D_{\text{KL}}(f, g) := \int f(x) \log \frac{f(x)}{g(x)} dx$$

a la divergencia de Kullback-Leibler entre  $f$  y  $g$ . Recordemos que

- $D_{\text{KL}}(f, g) \geq 0$  para cualesquiera  $f, g$ , y que
- $D_{\text{KL}}(f, f) = 0$ .

## Máxima verosimilitud y máximo a posteriori

Sea  $\mathcal{F} = \{f_\theta \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$  (con  $f$  no necesariamente en  $\mathcal{F}$ ).

## Máxima verosimilitud y máximo a posteriori

Sea  $\mathcal{F} = \{f_\theta \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$  (con  $f$  no necesariamente en  $\mathcal{F}$ ). Habiendo observado  $(X_1, \dots, X_n) = (x_1, \dots, x_n)$ , denotamos por

$$L_n(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

a la función de verosimilitud.

## Máxima verosimilitud y máximo a posteriori

Sea  $\mathcal{F} = \{f_\theta \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$  (con  $f$  no necesariamente en  $\mathcal{F}$ ). Habiendo observado  $(X_1, \dots, X_n) = (x_1, \dots, x_n)$ , denotamos por

$$L_n(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

a la función de verosimilitud. Definimos el *estimador de máxima verosimilitud* como

$$\hat{\theta}_n^{\text{EMV}} := \arg \max_{\theta \in \Theta} \{L_n(\theta)\}.$$

## Máxima verosimilitud y máximo a posteriori

Sea  $\mathcal{F} = \{f_\theta \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$  (con  $f$  no necesariamente en  $\mathcal{F}$ ). Habiendo observado  $(X_1, \dots, X_n) = (x_1, \dots, x_n)$ , denotamos por

$$L_n(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

a la función de verosimilitud. Definimos el *estimador de máxima verosimilitud* como

$$\hat{\theta}_n^{\text{EMV}} := \arg \max_{\theta \in \Theta} \{L_n(\theta)\}.$$

En el contexto bayesiano suponemos una distribución a priori  $p(\theta)$ . Definimos el *estimador máximo a posteriori* como

$$\hat{\theta}_n^{\text{MAP}} := \arg \max_{\theta \in \Theta} \{p(\theta|x_1, \dots, x_n)\} = \arg \max_{\theta \in \Theta} \{p(x_1, \dots, x_n|\theta)p(\theta)\}.$$

## Máxima verosimilitud y máximo a posteriori

Sea  $\mathcal{F} = \{f_\theta \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$  (con  $f$  no necesariamente en  $\mathcal{F}$ ). Habiendo observado  $(X_1, \dots, X_n) = (x_1, \dots, x_n)$ , denotamos por

$$L_n(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

a la función de verosimilitud. Definimos el *estimador de máxima verosimilitud* como

$$\hat{\theta}_n^{\text{EMV}} := \arg \max_{\theta \in \Theta} \{L_n(\theta)\}.$$

En el contexto bayesiano suponemos una distribución a priori  $p(\theta)$ . Definimos el *estimador máximo a posteriori* como

$$\hat{\theta}_n^{\text{MAP}} := \arg \max_{\theta \in \Theta} \{p(\theta|x_1, \dots, x_n)\} = \arg \max_{\theta \in \Theta} \{p(x_1, \dots, x_n|\theta)p(\theta)\}.$$

En particular, si  $\theta$  se distribuye uniformemente (i.e.  $p(\theta)$  es constante) y  $p(x_1, \dots, x_n|\theta) = \prod_{i=1}^n f(x_i; \theta)$ , entonces  $\hat{\theta}_n^{\text{MAP}} = \hat{\theta}_n^{\text{EMV}}$ .

Por otro lado, denotemos

$$\ell_n(\theta) := \log L_n(\theta) = \log \prod_{i=1}^n f(x_i; \theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Por otro lado, denotemos

$$\ell_n(\theta) := \log L_n(\theta) = \log \prod_{i=1}^n f(x_i; \theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Sabemos que maximizar  $L_n(\theta)$  es equivalente a maximizar  $\ell_n(\theta)$ . Más aun, maximizar  $\ell_n(\theta)$  es equivalente a maximizar

$$M_n(\theta) = M_n(\theta; x_1, \dots, x_n) := \frac{1}{n} \sum_{i=1}^n \log \frac{f(x_i; \theta)}{f(x_i)}$$

pues  $M_n(\theta) = \frac{1}{n}(\ell_n(\theta) - c)$  donde  $c$  no depende de  $\theta$ .

Por otro lado, denotemos

$$\ell_n(\theta) := \log L_n(\theta) = \log \prod_{i=1}^n f(x_i; \theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Sabemos que maximizar  $L_n(\theta)$  es equivalente a maximizar  $\ell_n(\theta)$ . Más aun, maximizar  $\ell_n(\theta)$  es equivalente a maximizar

$$M_n(\theta) = M_n(\theta; x_1, \dots, x_n) := \frac{1}{n} \sum_{i=1}^n \log \frac{f(x_i; \theta)}{f(x_i)}$$

pues  $M_n(\theta) = \frac{1}{n}(\ell_n(\theta) - c)$  donde  $c$  no depende de  $\theta$ . Por la LGN,

$$M_n(\theta) \xrightarrow{P} \mathbb{E}_f \left( \log \frac{f(X; \theta)}{f(X)} \right) = \int f(x) \log \frac{f(x; \theta)}{f(x)} dx = -D_{\text{KL}}(f, f_\theta). \quad (1)$$

Por otro lado, denotemos

$$\ell_n(\theta) := \log L_n(\theta) = \log \prod_{i=1}^n f(x_i; \theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Sabemos que maximizar  $L_n(\theta)$  es equivalente a maximizar  $\ell_n(\theta)$ . Más aun, maximizar  $\ell_n(\theta)$  es equivalente a maximizar

$$M_n(\theta) = M_n(\theta; x_1, \dots, x_n) := \frac{1}{n} \sum_{i=1}^n \log \frac{f(x_i; \theta)}{f(x_i)}$$

pues  $M_n(\theta) = \frac{1}{n}(\ell_n(\theta) - c)$  donde  $c$  no depende de  $\theta$ . Por la LGN,

$$M_n(\theta) \xrightarrow{P} \mathbb{E}_f \left( \log \frac{f(X; \theta)}{f(X)} \right) = \int f(x) \log \frac{f(x; \theta)}{f(x)} dx = -D_{\text{KL}}(f, f_\theta). \quad (1)$$

Intuitivamente, esperaríamos que de esto se siguiera que

$$\arg \max_{\theta \in \Theta} \{M_n(\theta)\} \xrightarrow{P} \arg \max_{\theta \in \Theta} \{-D_{\text{KL}}(f, f_\theta)\}.$$

Por otro lado, denotemos

$$\ell_n(\theta) := \log L_n(\theta) = \log \prod_{i=1}^n f(x_i; \theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Sabemos que maximizar  $L_n(\theta)$  es equivalente a maximizar  $\ell_n(\theta)$ . Más aun, maximizar  $\ell_n(\theta)$  es equivalente a maximizar

$$M_n(\theta) = M_n(\theta; x_1, \dots, x_n) := \frac{1}{n} \sum_{i=1}^n \log \frac{f(x_i; \theta)}{f(x_i)}$$

pues  $M_n(\theta) = \frac{1}{n}(\ell_n(\theta) - c)$  donde  $c$  no depende de  $\theta$ . Por la LGN,

$$M_n(\theta) \xrightarrow{P} \mathbb{E}_f \left( \log \frac{f(X; \theta)}{f(X)} \right) = \int f(x) \log \frac{f(x; \theta)}{f(x)} dx = -D_{\text{KL}}(f, f_\theta). \quad (1)$$

Intuitivamente, esperaríamos que de esto se siguiera que

$$\arg \max_{\theta \in \Theta} \{M_n(\theta)\} \xrightarrow{P} \arg \max_{\theta \in \Theta} \{-D_{\text{KL}}(f, f_\theta)\}.$$

O equivalentemente, que

$$\hat{\theta}_n^{\text{EMV}} \xrightarrow{P} \arg \min_{\theta \in \Theta} \{D_{\text{KL}}(f, f_\theta)\}.$$

Sin embargo, en general esto no es cierto. Por eso pediremos dos cosas:

Sin embargo, en general esto no es cierto. Por eso pediremos dos cosas:

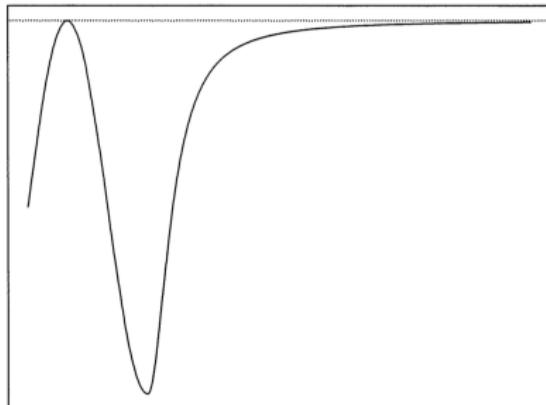
1. Pediremos que  $M_n(\theta)$  converga uniformemente en probabilidad a  $-D_{\text{KL}}(f, f_\theta)$ . (En contraste con  $M_n(\theta) \xrightarrow{P} -D_{\text{KL}}(f, f_\theta)$ ).

Sin embargo, en general esto no es cierto. Por eso pediremos dos cosas:

1. Pediremos que  $M_n(\theta)$  converga uniformemente en probabilidad a  $-D_{\text{KL}}(f, f_\theta)$ . (En contraste con  $M_n(\theta) \xrightarrow{P} -D_{\text{KL}}(f, f_\theta)$ ).
2. Pediremos que la función  $\theta \mapsto D_{\text{KL}}(f, f_\theta)$  se maximice en un único punto  $\theta_*$  y más aun, pediremos que solo parámetros cercanos  $\theta_*$  obtengan valores cercanos a  $M(\theta_*)$ .

Sin embargo, en general esto no es cierto. Por eso pediremos dos cosas:

1. Pediremos que  $M_n(\theta)$  converga uniformemente en probabilidad a  $-D_{\text{KL}}(f, f_\theta)$ . (En contraste con  $M_n(\theta) \xrightarrow{P} -D_{\text{KL}}(f, f_\theta)$ ).
2. Pediremos que la función  $\theta \mapsto D_{\text{KL}}(f, f_\theta)$  se maximice en un único punto  $\theta_*$  y más aun, pediremos que solo parámetros cercanos  $\theta_*$  obtengan valores cercanos a  $M(\theta_*)$ .



Maximizar  $L_n(\theta)$  es asintóticamente equivalente a minimizar  $D_{KL}$

### Teorema

Sea  $\mathcal{F} = \{f(\cdot; \theta) \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$ .

---

<sup>1</sup>En el caso que  $f \in \mathcal{F}$ , esta hipótesis es consecuencia de otra hipótesis conocida como *identificabilidad* del modelo.

Maximizar  $L_n(\theta)$  es asintóticamente equivalente a minimizar  $D_{KL}$

### Teorema

Sea  $\mathcal{F} = \{f(\cdot; \theta) \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$ . Denotemos

$$M_n(\theta) := \frac{1}{n} \sum_{i=1}^n \log \frac{f(x_i; \theta)}{f(x_i)}, \quad M(\theta) = -D_{KL}(f, f_\theta).$$

---

<sup>1</sup>En el caso que  $f \in \mathcal{F}$ , esta hipótesis es consecuencia de otra hipótesis conocida como *identificabilidad* del modelo.

Maximizar  $L_n(\theta)$  es asintóticamente equivalente a minimizar  $D_{KL}$

### Teorema

Sea  $\mathcal{F} = \{f(\cdot; \theta) \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$ . Denotemos

$$M_n(\theta) := \frac{1}{n} \sum_{i=1}^n \log \frac{f(x_i; \theta)}{f(x_i)}, \quad M(\theta) = -D_{KL}(f, f_\theta).$$

Si  $\theta_\star := \arg \min_{\theta \in \Theta} \{D_{KL}(f, f_\theta)\}$  esta bien definido<sup>1</sup>,

$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{P} 0, \tag{H1}$$

$$\forall \epsilon > 0, \quad \sup_{\theta: |\theta - \theta_\star| \geq \epsilon} M(\theta) < M(\theta_\star), \tag{H2}$$

---

<sup>1</sup>En el caso que  $f \in \mathcal{F}$ , esta hipótesis es consecuencia de otra hipótesis conocida como *identificabilidad* del modelo.

Maximizar  $L_n(\theta)$  es asintóticamente equivalente a minimizar  $D_{KL}$

### Teorema

Sea  $\mathcal{F} = \{f(\cdot; \theta) \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$ . Denotemos

$$M_n(\theta) := \frac{1}{n} \sum_{i=1}^n \log \frac{f(x_i; \theta)}{f(x_i)}, \quad M(\theta) = -D_{KL}(f, f_\theta).$$

Si  $\theta_\star := \arg \min_{\theta \in \Theta} \{D_{KL}(f, f_\theta)\}$  esta bien definido<sup>1</sup>,

$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{P} 0, \tag{H1}$$

$$\forall \epsilon > 0, \quad \sup_{\theta: |\theta - \theta_\star| \geq \epsilon} M(\theta) < M(\theta_\star), \tag{H2}$$

entonces

$$\hat{\theta}_n^{\text{EMV}} \xrightarrow{P} \theta_\star = \arg \min_{\theta \in \Theta} \{D_{KL}(f, f_\theta)\}.$$

---

<sup>1</sup>En el caso que  $f \in \mathcal{F}$ , esta hipótesis es consecuencia de otra hipótesis conocida como *identificabilidad* del modelo.

Maximizar  $L_n(\theta)$  es asintóticamente equivalente a minimizar  $D_{KL}$

### Teorema

Sea  $\mathcal{F} = \{f(\cdot; \theta) \mid \theta \in \Theta\}$  un modelo paramétrico y sea  $X_1, \dots, X_n$  una muestra aleatoria de  $f$ . Denotemos

$$M_n(\theta) := \frac{1}{n} \sum_{i=1}^n \log \frac{f(x_i; \theta)}{f(x_i)}, \quad M(\theta) = -D_{KL}(f, f_\theta).$$

Si  $\theta_\star := \arg \min_{\theta \in \Theta} \{D_{KL}(f, f_\theta)\}$  esta bien definido<sup>1</sup>,

$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{P} 0, \tag{H1}$$

$$\forall \epsilon > 0, \quad \sup_{\theta: |\theta - \theta_\star| \geq \epsilon} M(\theta) < M(\theta_\star), \tag{H2}$$

entonces

$$\hat{\theta}_n^{\text{EMV}} \xrightarrow{P} \theta_\star = \arg \min_{\theta \in \Theta} \{D_{KL}(f, f_\theta)\}.$$

En particular, si  $f = f_{\theta_0}$  para algun  $\theta_0 \in \Theta$ , entonces  $\hat{\theta}_n^{\text{EMV}} \xrightarrow{P} \theta_0$ .

---

<sup>1</sup>En el caso que  $f \in \mathcal{F}$ , esta hipótesis es consecuencia de otra hipótesis conocida como *identificabilidad* del modelo.

*Demostración.* Denotemos  $\hat{\theta}_n = \hat{\theta}_n^{\text{EMV}}$ .

*Demostración.* Denotemos  $\hat{\theta}_n = \hat{\theta}_n^{\text{EMV}}$ . Notemos que

$$\begin{aligned} M(\theta_*) - M(\hat{\theta}_n) &= M(\theta_*) - M_n(\theta_*) + M_n(\theta_*) - M(\hat{\theta}_n) \\ &\leq \sup_{\theta \in \Theta} |M(\theta) - M_n(\theta)| + M_n(\hat{\theta}_n) - M(\hat{\theta}_n) \\ &\quad (\hat{\theta}_n \text{ maximiza } M_n) \\ &\xrightarrow{P} 0. \quad (\text{por (1) y (H1)}) \end{aligned}$$

*Demostración.* Denotemos  $\hat{\theta}_n = \hat{\theta}_n^{\text{EMV}}$ . Notemos que

$$\begin{aligned} M(\theta_\star) - M(\hat{\theta}_n) &= M(\theta_\star) - M_n(\theta_\star) + M_n(\theta_\star) - M(\hat{\theta}_n) \\ &\leq \sup_{\theta \in \Theta} |M(\theta) - M_n(\theta)| + M_n(\hat{\theta}_n) - M(\hat{\theta}_n) \\ &\quad (\hat{\theta}_n \text{ maximiza } M_n) \\ &\xrightarrow{P} 0. \quad (\text{por (1) y (H1)}) \end{aligned}$$

En particular, para cualquier  $\delta > 0$

$$P \left( M(\hat{\theta}_n) < M(\theta_\star) - \delta \right) \rightarrow 0. \quad (2)$$

*Demostración.* Denotemos  $\hat{\theta}_n = \hat{\theta}_n^{\text{EMV}}$ . Notemos que

$$\begin{aligned} M(\theta_*) - M(\hat{\theta}_n) &= M(\theta_*) - M_n(\theta_*) + M_n(\theta_*) - M(\hat{\theta}_n) \\ &\leq \sup_{\theta \in \Theta} |M(\theta) - M_n(\theta)| + M_n(\hat{\theta}_n) - M(\hat{\theta}_n) \\ &\quad (\hat{\theta}_n \text{ maximiza } M_n) \\ &\xrightarrow{P} 0. \quad (\text{por (1) y (H1)}) \end{aligned}$$

En particular, para cualquier  $\delta > 0$

$$P\left(M(\hat{\theta}_n) < M(\theta_*) - \delta\right) \rightarrow 0. \quad (2)$$

Por otro lado, sea  $\epsilon > 0$  arbitrario y sea

$$\delta = M(\theta_*) - \sup_{\theta: |\theta - \theta_*| \geq \epsilon} M(\theta) > 0. \quad (\text{por (H2)})$$

*Demostración.* Denotemos  $\hat{\theta}_n = \hat{\theta}_n^{\text{EMV}}$ . Notemos que

$$\begin{aligned} M(\theta_*) - M(\hat{\theta}_n) &= M(\theta_*) - M_n(\theta_*) + M_n(\theta_*) - M(\hat{\theta}_n) \\ &\leq \sup_{\theta \in \Theta} |M(\theta) - M_n(\theta)| + M_n(\hat{\theta}_n) - M(\hat{\theta}_n) \\ &\quad (\hat{\theta}_n \text{ maximiza } M_n) \\ &\xrightarrow{P} 0. \quad (\text{por (1) y (H1)}) \end{aligned}$$

En particular, para cualquier  $\delta > 0$

$$P \left( M(\hat{\theta}_n) < M(\theta_*) - \delta \right) \rightarrow 0. \quad (2)$$

Por otro lado, sea  $\epsilon > 0$  arbitrario y sea

$$\delta = M(\theta_*) - \sup_{\theta: |\theta - \theta_*| \geq \epsilon} M(\theta) > 0. \quad (\text{por (H2)})$$

De esta manera,  $|\theta - \theta_*| \geq \epsilon$  implica  $M(\theta) < M(\theta_*) - \delta$ .

*Demostración.* Denotemos  $\hat{\theta}_n = \hat{\theta}_n^{\text{EMV}}$ . Notemos que

$$\begin{aligned}
 M(\theta_*) - M(\hat{\theta}_n) &= M(\theta_*) - M_n(\theta_*) + M_n(\theta_*) - M(\hat{\theta}_n) \\
 &\leq \sup_{\theta \in \Theta} |M(\theta) - M_n(\theta)| + M_n(\hat{\theta}_n) - M(\hat{\theta}_n) \\
 &\quad (\hat{\theta}_n \text{ maximiza } M_n) \\
 &\xrightarrow{P} 0. \quad (\text{por (1) y (H1)})
 \end{aligned}$$

En particular, para cualquier  $\delta > 0$

$$P\left(M(\hat{\theta}_n) < M(\theta_*) - \delta\right) \rightarrow 0. \quad (2)$$

Por otro lado, sea  $\epsilon > 0$  arbitrario y sea

$$\delta = M(\theta_*) - \sup_{\theta: |\theta - \theta_*| \geq \epsilon} M(\theta) > 0. \quad (\text{por (H2)})$$

De esta manera,  $|\theta - \theta_*| \geq \epsilon$  implica  $M(\theta) < M(\theta_*) - \delta$ . Por lo tanto,

$$P\left(|\hat{\theta}_n - \theta_*| > \epsilon\right) \leq P\left(M(\hat{\theta}_n) < M(\theta_*) - \delta\right) \xrightarrow{P} 0.$$

□