

Tarea 2

Temas selectos de estadística
Aprendizaje de máquina probabilístico
Semestre 2025-1

Diego Leipen Lara

1. En el modelo de regresión lineal

$$y = X_0\beta_0 + \epsilon_0, \quad \epsilon_0 \sim \mathcal{N}_n(0, \sigma_0^2 I_n) \quad (1)$$

donde X tiene dimensión $n \times p$, al estar considerando intercepto, y β_0 es tal que, con $0 < p_0 \leq p$, sus últimas $p - p_0$ entradas son cero. Más aún, utilizamos el modelo

$$y = X\beta + \epsilon, \quad \epsilon \sim \mathcal{N}_n(0, \sigma^2 I_n). \quad (2)$$

Sean $\theta_0 = (\beta'_0, \sigma_0^2)$ y $\theta = (\beta', \sigma^2)$. El criterio de información de Akaike corregido para el modelo (2) es

$$\text{AIC}_c := -2 \log(f(y; \theta)) + \frac{2n \dim \theta}{n - \dim \theta - 1}.$$

1. Muestre que en general

$$\text{AIC}_c = \text{AIC} + \frac{2 \dim \theta^2 + 2 \dim \theta}{n - \dim \theta - 1}.$$

2. Para el modelo (2) utilizando los estimadores

$$\hat{\beta}_n := (X'X)^{-1}X'y, \quad \hat{\sigma}_n^2 := \frac{1}{n}(y - X\hat{\beta}_n)'(y - X\hat{\beta}_n)$$

exprese analíticamente el AIC_c .

3. Muestre que

$$\mathbb{E}_0 \left[-2 \log(f(y; \theta_0)) \right] - \mathbb{E}_0 \left[-2 \log(f(y; \hat{\theta}_n)) \right] = -\mathbb{E}_0 \left[n \log \left(\frac{\hat{\sigma}_n^2}{\sigma_0^2} \right) \right].$$

4. Muestre que

$$\mathbb{E}_0 \left[\mathbb{E}_0 \left[-2 \log(f(y; \theta)) \right] \Big|_{\theta=\hat{\theta}_n} \right] - \mathbb{E}_0 \left[-2 \log(f(y; \theta_0)) \right] = \mathbb{E}_0 \left[n \log \left(\frac{\hat{\sigma}_n^2}{\sigma_0^2} \right) \right] + \frac{2(p+1)n}{n-p-2}.$$

5. Para la discrepancia de Kullback

$$d(\hat{\theta}_n, \theta_0) = \mathbb{E}_0 \left[-2 \log(f(y; \theta)) \right] \Big|_{\theta=\hat{\theta}_n}$$

muestre que

$$\mathbb{E}_0[\text{AIC}_c] = \mathbb{E}_0 \left[d(\hat{\theta}_n, \theta_0) \right].$$

Demostración.

1. Calculando directamente,

$$\begin{aligned}
\text{AIC} &+ \frac{2 \dim \theta^2 + 2 \dim \theta}{n - \dim \theta - 1} \\
&= -2 \log \left(f(y; \hat{\theta}_n) \right) + 2 \dim \theta + \frac{2 \dim \theta^2 + 2 \dim \theta}{n - \dim \theta - 1} \\
&= -2 \log \left(f(y; \hat{\theta}_n) \right) + \frac{2 \dim \theta (n - \dim \theta - 1) + 2 \dim \theta^2 + 2 \dim \theta}{n - \dim \theta - 1} \\
&= -2 \log \left(f(y; \hat{\theta}_n) \right) + \frac{2 \dim \theta n}{n - \dim \theta - 1} \\
&= \text{AIC}_c.
\end{aligned}$$

2. Calculando directamente,

$$f(y; \hat{\theta}_n) = \frac{1}{(2\pi\hat{\sigma}_n^2)^{n/2}} \exp \left\{ -\frac{1}{2\hat{\sigma}_n^2} (y - X\hat{\beta}_n)'(y - X\hat{\beta}_n) \right\} = \frac{1}{(2\pi\hat{\sigma}_n^2)^{n/2}} \exp \left\{ -\frac{n}{2} \right\}.$$

Entonces

$$\log \left(f(y; \hat{\theta}_n) \right) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}_n^2) - \frac{n}{2}. \quad (3)$$

Por lo tanto,

$$\begin{aligned}
\text{AIC}_c &= -2 \log \left(f(y; \theta) \right) + \frac{2n \dim \theta}{n - \dim \theta - 1} \\
&= -n \log(2\pi) - n \log(\hat{\sigma}_n^2) - n + \frac{2n \dim \theta}{n - \dim \theta - 1}.
\end{aligned}$$

3. Primero notemos que por (3)

$$\mathbb{E}_0 \left[-2 \log \left(f(y; \hat{\theta}_n) \right) \right] = n \log(2\pi) + \mathbb{E}_0 \left[n \log(\hat{\sigma}_n^2) \right] + n. \quad (4)$$

Por otro lado,

$$f(y; \theta_0) = \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp \left\{ -\frac{1}{2\sigma_0^2} (y - X_0\beta_0)'(y - X_0\beta_0) \right\}.$$

Entonces

$$\log \left(f(y; \theta_0) \right) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma_0^2) - \frac{1}{2\sigma_0^2} (y - X_0\beta_0)'(y - X_0\beta_0).$$

Más aun,

$$\begin{aligned}
\mathbb{E}_0 \left[(y - X_0\beta_0)'(y - X_0\beta_0) \right] &= \mathbb{E}_0 \left[\sum_{i=1}^n (y_i - (X_0\beta_0)_i)^2 \right] \\
&= \sum_{i=1}^n \mathbb{E}_0 \left[(y_i - (X_0\beta_0)_i)^2 \right] \\
&= \sum_{i=1}^n \left\{ \text{Var}_0 \left[y_i - (X_0\beta_0)_i \right] + \left(\mathbb{E}_0 \left[y_i - (X_0\beta_0)_i \right] \right)^2 \right\} \\
&= \sum_{i=1}^n \left\{ \sigma_0^2 + 0^2 \right\} \\
&= n\sigma_0^2
\end{aligned}$$

donde la cuarta igualdad se cumple porque $\text{Var}_0 [y_i - (X_0\beta_0)_i] = \text{Var}_0 [y_i] = \sigma_0^2$. Entonces

$$\mathbb{E}_0 \left[-2 \log (f(y; \theta_0)) \right] = n \log(2\pi) + \mathbb{E}_0 \left[n \log(\sigma_0^2) \right] + n. \quad (5)$$

Juntando (4) y (5) obtenemos

$$\begin{aligned} \mathbb{E}_0 \left[-2 \log (f(y; \theta_0)) \right] - \mathbb{E}_0 \left[-2 \log (f(y; \hat{\theta}_n)) \right] &= \mathbb{E}_0 \left[n \log(\sigma_0^2) \right] - \mathbb{E}_0 \left[n \log(\hat{\sigma}_n^2) \right] \\ &= -\mathbb{E}_0 \left[n \log \left(\frac{\hat{\sigma}_n^2}{\sigma_0^2} \right) \right]. \end{aligned}$$

4. Calculando directamente,

$$f(y; \theta) = \frac{1}{(2\pi\hat{\sigma}_n^2)^{n/2}} \exp \left\{ -\frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta) \right\}.$$

Entonces

$$\log (f(y, \theta)) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta).$$

Más aun,

$$\begin{aligned} \mathbb{E}_0 [(y - X\beta)'(y - X\beta)] &= \mathbb{E}_0 \left[\sum_{i=1}^n (y_i - (X\beta)_i)^2 \right] \\ &= \sum_{i=1}^n \mathbb{E}_0 [(y_i - (X\beta)_i)^2] \\ &= \sum_{i=1}^n \left\{ \text{Var}_0 [y_i - (X\beta)_i] + \left(\mathbb{E}_0 [y_i - (X\beta)_i] \right)^2 \right\} \\ &= \sum_{i=1}^n \left\{ \sigma_0^2 + ((X_0\beta_0)_i - (X\beta)_i)^2 \right\} \\ &= n\sigma_0^2 + (X_0\beta_0 - X\beta)'(X_0\beta_0 - X\beta). \end{aligned}$$

Entonces

$$\begin{aligned} \mathbb{E}_0 \left[-2 \log (f(y, \theta)) \right] &= n \log(2\pi) + n \log(\sigma^2) + \frac{1}{\sigma^2} \left(n\sigma_0^2 + (X_0\beta_0 - X\beta)'(X_0\beta_0 - X\beta) \right) \\ &= n \log(2\pi) + n \log(\sigma^2) + \frac{n\sigma_0^2}{\sigma^2} + \frac{(X_0\beta_0 - X\beta)'(X_0\beta_0 - X\beta)}{\sigma^2}. \end{aligned}$$

Entonces

$$\mathbb{E}_0 \left[-2 \log (f(y, \theta)) \right] |_{\theta=\hat{\theta}_n} = n \log(2\pi) + n \log(\hat{\sigma}_n^2) + \frac{n\sigma_0^2}{\hat{\sigma}_n^2} + \frac{(X_0\beta_0 - X\hat{\beta}_n)'(X_0\beta_0 - X\hat{\beta}_n)}{\hat{\sigma}_n^2}.$$

Pero en el articulo *Estimation Optimality of Corrected AIC and Modified Cp in Linear Regression* de Davies, Neath, y Cavanaugh (justo despues de la ecuación 3.3) se menciona que

$$\begin{aligned} \frac{n\sigma_0^2}{\hat{\sigma}_n^2} &\sim \chi_{n-p}^2, \\ \frac{(X_0\beta_0 - X\hat{\beta}_n)'(X_0\beta_0 - X\hat{\beta}_n)}{\sigma_0^2} &\sim \chi_p^2. \end{aligned}$$

Entonces

$$\mathbb{E}_0 \left[\frac{n\sigma_0^2}{\hat{\sigma}_n^2} \right] = n^2 \mathbb{E}_0 \left[\frac{\sigma_0^2}{n\hat{\sigma}_n^2} \right] = n^2 \left(\frac{1}{n-p-2} \right)$$

donde la ultima igualdad se cumple porque si $Z \sim \chi_k^2$, entonces $\mathbb{E}[\frac{1}{Z}] = \frac{1}{k-2}$. Más aun,

$$\begin{aligned} \mathbb{E}_0 \left[\frac{(X_0\beta_0 - X\hat{\beta}_n)'(X_0\beta_0 - X\hat{\beta}_n)}{\hat{\sigma}_n^2} \right] &= n \mathbb{E}_0 \left[\frac{\frac{\sigma_0^2}{n\hat{\sigma}_n^2} (X_0\beta_0 - X\hat{\beta}_n)'(X_0\beta_0 - X\hat{\beta}_n)}{\sigma_0^2} \right] \\ &= n \mathbb{E}_0 \left[\frac{\sigma_0^2}{n\hat{\sigma}_n^2} \right] \mathbb{E}_0 \left[\frac{(X_0\beta_0 - X\hat{\beta}_n)'(X_0\beta_0 - X\hat{\beta}_n)}{\sigma_0^2} \right] \\ &= n \left(\frac{1}{n-p-2} \right) p \end{aligned}$$

donde la segunda igualdad se cumple por independencia de $\hat{\beta}_n$ y $\hat{\sigma}_n^2$. De esto se sigue que

$$\begin{aligned} &\mathbb{E}_0 \left[\mathbb{E}_0 \left[-2 \log(f(y, \theta)) \right] \Big|_{\theta=\hat{\theta}_n} \right] \\ &= \mathbb{E}_0 \left[n \log(2\pi) + n \log(\hat{\sigma}_n^2) + \frac{n\sigma_0^2}{\hat{\sigma}_n^2} + \frac{(X_0\beta_0 - X\hat{\beta}_n)'(X_0\beta_0 - X\hat{\beta}_n)}{\hat{\sigma}_n^2} \right] \\ &= n \log(2\pi) + \mathbb{E}_0 \left[n \log(\hat{\sigma}_n^2) \right] + \frac{n^2}{n-p-2} + \frac{np}{n-p-2}. \end{aligned}$$

Entonces

$$\begin{aligned} &\mathbb{E}_0 \left[\mathbb{E}_0 \left[-2 \log(f(y, \theta)) \right] \Big|_{\theta=\hat{\theta}_n} \right] - \mathbb{E}_0 \left[-2 \log(f(y; \theta_0)) \right] \\ &= n \log(2\pi) + \mathbb{E}_0 \left[n \log(\hat{\sigma}_n^2) \right] + \frac{n^2 + np}{n-p-2} - \left(n \log(2\pi) + \mathbb{E}_0 \left[n \log(\sigma_0^2) \right] + n \right) \quad (\text{cf. (5)}) \\ &= \mathbb{E}_0 \left[n \log \left(\frac{\hat{\sigma}_n^2}{\sigma_0^2} \right) \right] + \frac{2(p+1)n}{n-p-2}. \end{aligned}$$

5. Calculando directamente,

$$\begin{aligned} \mathbb{E}_0 \left[d(\hat{\theta}_n, \theta_0) \right] &= \mathbb{E}_0 \left[\mathbb{E}_0 \left[-2 \log(f(y; \theta)) \right] \Big|_{\theta=\hat{\theta}_n} \right] \\ &= \mathbb{E}_0 \left[-2 \log(f(y; \theta_0)) \right] + \mathbb{E}_0 \left[n \log \left(\frac{\hat{\sigma}_n^2}{\sigma_0^2} \right) \right] + \frac{2(p+1)n}{n-p-2} \quad (\text{por el inciso 4}) \\ &= \mathbb{E}_0 \left[-2 \log(f(y; \hat{\theta}_n)) \right] + \frac{2(p+1)n}{n-p-2} \quad (\text{por el inciso 3}) \\ &= \mathbb{E}_0[\text{AIC}_c]. \end{aligned}$$

□

2. Demuestre que para el problema de optimización

$$\min_{\beta \in \mathbb{R}^p} \left\{ \frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right\}$$

en caso de que X sea ortonormal, entonces

$$\beta^{\text{LASSO}} = \text{sign}(\hat{\beta}_i) \left(|\hat{\beta}_i| - \lambda \right)^+$$

con $\hat{\beta} = (X'X)^{-1}X'y$.

Demostración. Como X es ortonormal, $\hat{\beta} = (X'X)^{-1}X'y = X'y$. Entonces

$$\begin{aligned} \|y - X\beta\|_2^2 &= (y - X\beta)'(y - X\beta) \\ &= (y' - \beta'X')(y - X\beta) \\ &= y'y - y'X\beta - \beta'X'y + \beta'X'X\beta \\ &= \hat{\beta}'\hat{\beta} - \hat{\beta}'\beta - \beta'\hat{\beta} + \beta'\beta \\ &= \|\hat{\beta}\|_2^2 - 2 \sum_{i=1}^p \hat{\beta}_i\beta_i + \sum_{i=1}^p \beta_i^2. \end{aligned}$$

Entonces

$$\begin{aligned} &\min_{\beta \in \mathbb{R}^p} \left\{ \frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right\} \\ &= \min_{\beta \in \mathbb{R}^p} \left\{ \frac{1}{2} \left(\|\hat{\beta}\|_2^2 - 2 \sum_{i=1}^p \hat{\beta}_i\beta_i + \sum_{i=1}^p \beta_i^2 \right) + \lambda \|\beta\|_1 \right\} \\ &= \min_{\beta \in \mathbb{R}^p} \left\{ \frac{1}{2} \left(-2 \sum_{i=1}^p \hat{\beta}_i\beta_i + \sum_{i=1}^p \beta_i^2 \right) + \lambda \|\beta\|_1 \right\} \\ &= \min_{\beta \in \mathbb{R}^p} \left\{ \sum_{i=1}^p \left(-2\hat{\beta}_i\beta_i + \beta_i^2 + 2\lambda|\beta_i| \right) \right\} \\ &= \sum_{i=1}^p \min_{\beta_i \in \mathbb{R}} \left\{ -2\hat{\beta}_i\beta_i + \beta_i^2 + 2\lambda|\beta_i| \right\}. \end{aligned}$$

donde la segunda igualdad se cumple porque $\|\hat{\beta}\|_2^2$ no depende de β . Sean

$$\begin{aligned} f_i(\beta_i) &= -2\hat{\beta}_i\beta_i + \beta_i^2 + 2\lambda\beta_i, \\ g_i(\beta_i) &= -2\hat{\beta}_i\beta_i + \beta_i^2 - 2\lambda\beta_i. \end{aligned}$$

Entonces

$$\min_{\beta_i \in \mathbb{R}} \left\{ -2\hat{\beta}_i\beta_i + \beta_i^2 + 2\lambda|\beta_i| \right\} = \min \left\{ \min_{\beta_i \geq 0} f_i(\beta_i), \min_{\beta_i \leq 0} g_i(\beta_i) \right\}.$$

Además,

$$\begin{aligned} f'_i(\beta_i) &= -2\hat{\beta}_i + 2\beta_i + 2\lambda, \\ g'_i(\beta_i) &= -2\hat{\beta}_i + 2\beta_i - 2\lambda. \end{aligned}$$

Observación 1. Si $\hat{\beta}_i \leq \lambda$, entonces para todo $\beta_i \geq 0$

$$f'_i(\beta_i) = -2\hat{\beta}_i + 2\beta_i + 2\lambda \geq -2\lambda + 2\beta_i + 2\lambda = 2\beta_i \geq 0.$$

En particular, f_i es creciente en $(0, \infty)$ y $\min_{\beta_i \geq 0} f_i(\beta_i) = 0$.

Observación 2. Si $\hat{\beta}_i \geq -\lambda$, entonces para todo $\beta_i \leq 0$

$$g'_i(\beta_i) = -2\hat{\beta}_i + 2\beta_i - 2\lambda \leq 2\lambda + 2\beta_i - 2\lambda = 2\beta_i \leq 0.$$

En particular, g_i es decreciente en $(-\infty, 0)$ y $\min_{\beta_i \leq 0} g_i(\beta_i) = 0$.

Caso 1. $\hat{\beta}_i \in [-\lambda, \lambda]$.

Entonces por las observaciones anteriores

$$\min_{\beta_i \in \mathbb{R}} \left\{ -2\hat{\beta}_i\beta_i + \beta_i^2 + 2\lambda|\beta_i| \right\} = \min \left\{ \min_{\beta_i \geq 0} f_i(\beta_i), \min_{\beta_i \leq 0} g_i(\beta_i) \right\} = \min\{0, 0\} = 0.$$

Caso 2. $\hat{\beta}_i \in (-\infty, -\lambda)$.

Entonces $\hat{\beta}_i + \lambda < 0$ y es fácil verificar que $g'_i(\hat{\beta}_i + \lambda) = 0$. Usando esto y el hecho de que g_i es una función cuadrática convexa (el coeficiente de β_i^2 es $+1$) obtenemos la primera de las siguientes igualdades.

$$\begin{aligned} \min_{\beta_i \leq 0} g_i(\beta_i) &= g_i(\hat{\beta}_i + \lambda) \\ &= -2\hat{\beta}_i(\hat{\beta}_i + \lambda) + (\hat{\beta}_i + \lambda)^2 - 2\lambda(\hat{\beta}_i + \lambda) \\ &= -2\hat{\beta}_i^2 - 2\hat{\beta}_i\lambda + \hat{\beta}_i^2 + 2\hat{\beta}_i\lambda + \lambda^2 - 2\lambda\hat{\beta}_i - 2\lambda^2 \\ &= -\hat{\beta}_i^2 - 2\hat{\beta}_i\lambda - \lambda^2 \\ &= -(\hat{\beta}_i + \lambda)^2. \end{aligned}$$

Por otro lado, como $\hat{\beta}_i \in (-\infty, -\lambda)$, en particular $\hat{\beta}_i \leq \lambda$ y por la Obs. 1, $\min_{\beta_i \geq 0} f_i(\beta_i) = 0$. Por lo tanto,

$$\min_{\beta_i \in \mathbb{R}} \left\{ -2\hat{\beta}_i\beta_i + \beta_i^2 + 2\lambda|\beta_i| \right\} = \min \left\{ \min_{\beta_i \geq 0} f_i(\beta_i), \min_{\beta_i \leq 0} g_i(\beta_i) \right\} = \min\{0, -(\hat{\beta}_i + \lambda)^2\} = -(\hat{\beta}_i + \lambda)^2.$$

Caso 3. $\hat{\beta}_i \in (\lambda, \infty)$.

Entonces $\hat{\beta}_i - \lambda > 0$ y es fácil verificar que $f'_i(\hat{\beta}_i - \lambda) = 0$. Usando esto y el hecho de que f_i es una función cuadrática convexa (el coeficiente de β_i^2 es $+1$) obtenemos la primera de las siguientes igualdades.

$$\begin{aligned} \min_{\beta_i \geq 0} f_i(\beta_i) &= f_i(\hat{\beta}_i - \lambda) \\ &= -2\hat{\beta}_i(\hat{\beta}_i - \lambda) + (\hat{\beta}_i - \lambda)^2 + 2\lambda(\hat{\beta}_i - \lambda) \\ &= -2\hat{\beta}_i^2 + 2\hat{\beta}_i\lambda + \hat{\beta}_i^2 - 2\hat{\beta}_i\lambda + \lambda^2 + 2\lambda\hat{\beta}_i - 2\lambda^2 \\ &= -\hat{\beta}_i^2 + 2\hat{\beta}_i\lambda - \lambda^2 \\ &= -(\hat{\beta}_i - \lambda)^2. \end{aligned}$$

Por otro lado, como $\hat{\beta}_i \in (\lambda, \infty)$, en particular $\hat{\beta}_i \geq -\lambda$ y por la Obs. 2, $\min_{\beta_i \leq 0} g_i(\beta_i) = 0$. Por lo tanto,

$$\min_{\beta_i \in \mathbb{R}} \left\{ -2\hat{\beta}_i\beta_i + \beta_i^2 + 2\lambda|\beta_i| \right\} = \min \left\{ \min_{\beta_i \geq 0} f_i(\beta_i), \min_{\beta_i \leq 0} g_i(\beta_i) \right\} = \min\{-(\hat{\beta}_i - \lambda)^2, 0\} = -(\hat{\beta}_i - \lambda)^2.$$

En resumen,

$$\min_{\beta_i \in \mathbb{R}} \left\{ -2\hat{\beta}_i\beta_i + \beta_i^2 + 2\lambda|\beta_i| \right\} = \begin{cases} 0 & \text{si } \hat{\beta}_i \in [-\lambda, \lambda] \\ -(\hat{\beta}_i + \lambda)^2 & \text{si } \hat{\beta}_i \in (-\infty, -\lambda) \\ -(\hat{\beta}_i - \lambda)^2 & \text{si } \hat{\beta}_i \in (\lambda, \infty) \end{cases}$$

Por lo tanto,

$$\begin{aligned} \beta_i^{\text{LASSO}} &= \begin{cases} 0 & \text{si } \hat{\beta}_i \in [-\lambda, \lambda] \\ \hat{\beta}_i + \lambda & \text{si } \hat{\beta}_i \in (-\infty, -\lambda) \\ \hat{\beta}_i - \lambda & \text{si } \hat{\beta}_i \in (\lambda, \infty) \end{cases} \\ &= \text{sign}(\hat{\beta}_i) \left(|\hat{\beta}_i| - \lambda \right)^+. \end{aligned}$$

□

Lema 1. Sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ tal que $\arg \min_{\beta \in \mathbb{R}^p} f(\beta)$ es único. Entonces para cualquier $c \in \mathbb{R}$,

$$\arg \min_{\beta \in \mathbb{R}^p} f(c\beta) = \frac{1}{c} \arg \min_{\beta \in \mathbb{R}^p} f(\beta).$$

Demostración. Denotemos $\beta_0 = \arg \min_{\beta \in \mathbb{R}^p} f(\beta)$. Por definición,

$$f(c\beta_0) \leq f(c\beta) \quad \forall \beta \in \mathbb{R}^p.$$

En particular,

$$f(c\beta_0) \leq f(\beta) \quad \forall \beta \in \mathbb{R}^p.$$

Por lo tanto, $c\beta_0 = \arg \min_{\beta \in \mathbb{R}^p} f(\beta)$. □

3. La penalización de elastic net esta dada por el problema de optimización

$$b_1 = \arg \min_{\beta \in \mathbb{R}^p} \left\{ \|y - X\beta\|_2^2 + \lambda_2 \|\beta\|_2^2 + \lambda_1 \|\beta\|_1 \right\}.$$

Consideremos alternativamente el problema de optimización

$$b_2 = \arg \min_{\beta \in \mathbb{R}^p} \left\{ \|\tilde{y} - \tilde{X}\beta\|_2^2 + c\lambda_1 \|\beta\|_1 \right\}$$

donde

$$c = (1 + \lambda_2)^{-1/2}, \quad \tilde{X} = c \begin{pmatrix} X \\ \sqrt{\lambda_2} I_p \end{pmatrix}, \quad \tilde{y} = \begin{pmatrix} y \\ 0_{p \times 1} \end{pmatrix}.$$

Muestre que $b_1 = cb_2$ y explique cómo se puede entonces resolver elastic net mediante la solución de Lasso.

Demostración. Calculando directamente,

$$\begin{aligned} \|\tilde{y} - \tilde{X}\beta\|_2^2 &= \sum_{i=1}^{n+p} (\tilde{y}_i - (\tilde{X}\beta)_i)^2 \\ &= \sum_{i=1}^n (\tilde{y}_i - (\tilde{X}\beta)_i)^2 + \sum_{i=n+1}^{n+p} (\tilde{y}_i - (\tilde{X}\beta)_i)^2 \\ &= \sum_{i=1}^n (y_i - c(X\beta)_i)^2 + \sum_{i=n+1}^{n+p} (0 - c\sqrt{\lambda_2}\beta_{i-n})^2 \\ &= \|y - X(c\beta)\|_2^2 + \lambda_2 \|c\beta\|_2^2. \end{aligned}$$

Además, como $c > 0$, entonces $c\lambda_1 \|\beta\|_1 = \lambda_1 \|c\beta\|_1$. Por lo tanto,

$$\begin{aligned} b_2 &= \arg \min_{\beta \in \mathbb{R}^p} \left\{ \|\tilde{y} - \tilde{X}\beta\|_2^2 + c\lambda_1 \|\beta\|_1 \right\} \\ &= \arg \min_{\beta \in \mathbb{R}^p} \left\{ \|y - X(c\beta)\|_2^2 + \lambda_2 \|c\beta\|_2^2 + \lambda_1 \|c\beta\|_1 \right\} \\ &= \frac{1}{c} b_1 \end{aligned}$$

donde la última igualdad es por el lema 1. Finalmente, podemos resolver elastic net mediante el problema alternativo, el cual es un problema de tipo Lasso. □